CASO YELPCONNECT · OFICINA DE ARQUITECTURA DE DATOS

DOCUMENTO FORMAL DE ARQUITECTURA DE DATOS

Métricas confiables para mejorar la experiencia de usuario · Caso de uso del Área de Producto

Programa de Arquitectura de Datos · UTEC Posgrado · Capstone Project

Grupo 03 · Data Evolution

Versión 1.4 · 9 de noviembre de 2026

Ficha técnica del documento

Campo	Contenido
Título del proyecto	Arquitectura de datos integral y gobierno de la plataforma YelpConnect
Caso de uso prioritario	Área de Producto (Andrew Collins, VP of Product): calidad de la experiencia de usuario, calificación ponderada confiable y métricas de engagement
Sponsor ejecutivo	Laura Hernández, Chief Data Officer (CDO)
Sponsor de negocio	Andrew Collins, VP of Product
Organización	Universidad de Ingeniería y Tecnología (UTEC), Escuela de Posgrado
Equipo e integrantes	Data Evolution (Grupo 03): Jamir Huaman, Arquitecto de Datos y coordinador general · John Huerta, Modelador de Datos (relator M5) · Leonardo Pacheco, Steward de Gobierno (relator M1) · Gabriela Matto, Gestión y Coordinación (relatora M2) · Josuhe Sosa, Ingeniero de Datos (relator M4) · Martin Valencia, Analista de BI y Valor (relator M6 a M10)
Plataforma	Databricks Free Edition (cómputo serverless) · Delta Lake · Unity Catalog, catálogo `workspace` · PySpark y SQL
Marcos de referencia	TOGAF Standard 10 (ADM) · DAMA-DMBOK 2 · Modelado dimensional Kimball · Arquitectura Lakehouse medallion
Repositorio	GitHub `utecgrupo3/utec-data-architecture-program`, conectado como Git folder en el workspace de Databricks
Fuente de verdad del modelo	`02-Modelado/yelp_modelo_conceptual.drawio`, `yelp_modelo_logico.drawio`, `yelp_silver.txt` y `yelp_gold.txt`
Estado	Versión 1.4: diseño verificado contra la plataforma desplegada, el job y el dashboard publicado el 09/11/2026

CONTROL DEL DOCUMENTO

Estado por sección

El documento se construye por acumulación: cada módulo cierra su sección. Desde la versión 1.3 todas las secciones describen lo que existe en la plataforma; lo que aún depende de una firma o de una decisión queda en la sección 9.2.

Sección	Módulo que la alimenta	Estado
1. Resumen ejecutivo	Cierre del programa	Actualizado con resultados reales
2. Visión de arquitectura y SoAW (E1)	M1	Cerrada
3. Arquitectura de referencia (E2)	M5	Cerrada; ADR actualizados en v1.3
4. Modelo de datos conceptual, lógico y dimensional (E3)	M4	Cerrada; coincide con los diagramas de 02-Modelado
5. Estrategia de gobierno y matriz RACI (E6)	M2 · M5	Cerrada; RACI igual a `yelp_gov.raci_matrix`
6. Reglas de calidad en lenguaje de negocio (E5)	M2 · M3 · M6	Cerrada; 20 reglas con resultado de la última corrida
7. Requerimientos de información y KPIs (E8)	M9	Cerrada; alineada con el dashboard publicado (14 consultas) en v1.4
8. Modelo operativo y consideraciones FinOps	M10	Cerrada; tiempos y bitácora verificados en v1.4
9. Trazabilidad documento ↔ plataforma	Transversal	Viva; registro de discrepancias abierto
Anexos A a F	M3 y transversal	Glosario y diccionario cargados en `yelp_gov`

Historial de versiones

Versión	Fecha	Módulo	Cambio realizado y motivo	Autor
0.1	11/08/2026	M1 · Fundamentos	Documento base: SoAW, dolores de Andrew Collins y alcance.	Jamir Huaman
0.2	18/08/2026	M2 · Seguridad y Gobierno	Matriz RACI, modelo de roles, clasificación PII y dimensiones de calidad.	Leonardo Pacheco
0.3	25/08/2026	M3 · MDM y Metadata	Glosario de negocio, diccionario técnico y primeras reglas DQ en lenguaje de negocio.	Leonardo Pacheco
0.4	08/09/2026	M4 · Modelado Avanzado	Modelo conceptual, lógico 3FN en Silver y dimensional en Gold.	John Huerta
0.5	22/09/2026	M5 · Arquitectura Cloud	Arquitectura de referencia ABB → SBB, alternativas descartadas y ADR-01 y ADR-02.	John Huerta
1.0	06/10/2026	M6 a M10 · Consolidación	Trazabilidad con notebooks E3 a E8, bitácora FinOps y consultas del dashboard.	Todo el equipo
1.1	09/10/2026	Evaluación docente	Lineamientos de la sesión 19 (grano explícito en Gold, hechos atómicos y agregados separados, cohortes), zona de cuarentena, ADR-05 y ADR-06.	Equipo Data Evolution
1.2	09/10/2026	Modelado físico	Integración del modelo de Josuhe: entidad Amistad, votos enviados por el usuario, dirección y código postal, categoría principal.	Josuhe Sosa
1.3	**08/11/2026**	**Alineación con la plataforma**	Integra el aporte de John y el documento G3. Alinea todo el texto con	Equipo Data Evolution

Versión	Fecha	Módulo	Cambio realizado y motivo	Autor
			`yelp_modelo_logico.drawio`, `yelp_silver.txt`, `yelp_gold.txt` y el catálogo desplegado: nombres en inglés en todas las capas, categorías con tabla puente, golden record, Gold con claves naturales, 20 reglas DQ, glosario de 39 términos y diccionario de 198 columnas. Registra las discrepancias en la sección 9.2.	
1.4	**09/11/2026**	**Verificación final**	Alinea la sección 7 con el dashboard publicado: tres productos de datos de Producto (REQ-P0 a REQ-P7), gobierno de la CDO (REQ-G1 a REQ-G6), mes de referencia y preguntas de Genie con consulta de referencia. Verifica el Quality Gate y el historial del job; actualiza tiempos (8 a 9 minutos), CE-05, la bitácora 8.5 y registra D-11 y D-12. Aplica la identidad visual de Yelp.	Equipo Data Evolution

CONTENIDO

Control del documento 2
Estado por sección 2
Historial de versiones 2
1 · Resumen ejecutivo 6
1.1 Contexto y diagnóstico del problema 6
1.2 Solución de arquitectura implementada 6
1.3 Resultados construidos y verificables 6
1.4 Decisiones que se solicitan a la CDO 7
1.5 Recomendaciones siguientes 7
2 · Visión de arquitectura y SoAW (E1) 8
2.1 Sponsor 8
2.2 Stakeholders 8
2.3 Motivadores del negocio 9
2.4 Alcance 9
2.5 Criterios de éxito 10
2.6 Principios de arquitectura 10
2.7 Restricciones y supuestos 11
2.8 Roadmap 11
3 · Arquitectura de referencia (E2) 12
3.1 Capacidades de negocio 12
3.2 Vista de la arquitectura 12
3.3 Bloques de arquitectura (ABB → SBB) 14
3.4 Decisiones de arquitectura (ADR) 15
4 · Modelo de datos (E3) 17
4.1 Modelo conceptual 17
4.2 Modelo lógico de la capa Silver 19
4.3 Modelo dimensional de la capa Gold (Kimball) 22
4.4 Trazabilidad conceptual → lógico → físico 24
5 · Estrategia de gobierno y matriz RACI (E6) 26
5.1 Roles de gobierno 26
5.2 Matriz RACI por entidad 26
5.3 Matriz RACI por actividad 27
5.4 Política de clasificación 27
5.5 Marco normativo 28
5.6 Mecanismos de control y toma de decisiones 28
6 · Reglas de calidad en lenguaje de negocio (E5) 30
6.1 Dimensiones de calidad 30
6.2 Catálogo de reglas 30

6.3 Criticidad y tratamiento de fallas 33
6.4 Resultado de la última corrida 33
7 · Requerimientos de información y KPIs (E8) 36
7.1 Preguntas de negocio por stakeholder 36
7.2 Catálogo de KPIs 37
7.3 Consultas del dashboard (E8) 39
7.4 Diseño del dashboard y preguntas para Genie 40
8 · Modelo operativo y consideraciones FinOps 41
8.1 Cadencia de ejecución 41
8.2 Configuración del job 41
8.3 Volumetría y tiempos de la última corrida 41
8.4 Supuestos de consumo 42
8.5 Bitácora de consumo 42
9 · Trazabilidad documento ↔ plataforma 43
9.1 Matriz de trazabilidad 43
9.2 Registro de discrepancias 43
Anexos 45
Anexo A · Glosario de términos de negocio 45
Anexo B · Diccionario de datos e inventario de tablas 49
Anexo C · Archivos fuente y diagramas 51
Anexo D · Actas de decisión del equipo 52
Anexo E · Referencias regulatorias y de uso 52
Anexo F · Supuestos y preguntas abiertas 52
Aprobación 52

Si los números de página no aparecen, en Word haz clic derecho sobre el índice → Actualizar campo.

1 · RESUMEN EJECUTIVO

Dirigido a Laura Hernández, CDO, y a Andrew Collins, VP of Product.

1.1 Contexto y diagnóstico del problema

YelpConnect es el canal principal de interacción entre millones de comensales y negocios locales en más de 30 países. El crecimiento desarticulado de nuevas funciones (Yelp Ads, Waitlist y Reservations) multiplicó las fuentes de datos sin que nadie respondiera por ellas.

Para Andrew Collins, VP of Product, el resultado es una crisis de confianza: las métricas de salud del producto cambian según el área que las consulta. Producto calcula la calificación y la retención con eventos sin depurar, Marketing reporta crecimiento de reseñas inflado por duplicados de campañas y Operaciones Comerciales cuenta cada marca de tiempo repetida de los check-ins. A eso se suman negocios con calificaciones extremas basadas en una sola reseña, entidades sin Data Owner, datasets sin linaje y modelos de recomendación entrenados sobre fuentes sin versionar.

1.2 Solución de arquitectura implementada

La Oficina de Arquitectura de Datos implementó una plataforma Lakehouse medallion en Databricks, gobernada de extremo a extremo con Unity Catalog:

1. **Bronze (`workspace.yelp_bronze`):** ingesta cruda e inmutable. Auto Loader procesa las reseñas de forma incremental y el resto se carga por lotes. Cada fila guarda su archivo de origen y su momento de ingesta (`_source_file`, `_ingested_at`).
2. **Silver (`workspace.yelp_silver`):** diez tablas en tercera forma normal, con tipos estrictos, golden record de negocios (`master_business_id`), categorías normalizadas en tabla puente, red de amistades y una zona de cuarentena explícita (`slv_review_quarantine`) para las reseñas que incumplen reglas.
3. **Gold (`workspace.yelp_gold`):** modelo dimensional Kimball con grano declarado en cada tabla: cuatro dimensiones, una tabla puente, tres hechos atómicos y ocho agregados por consumidor, entre ellos el rating bayesiano y la retención de cohortes.
4. **Gobierno (`workspace.yelp_gov`):** glosario, diccionario, catálogo y resultados de reglas DQ, matriz RACI y bitácora del pipeline, más tags de clasificación, permisos por esquema y enmascaramiento dinámico del nombre de los usuarios.

1.3 Resultados construidos y verificables

Resultado	Evidencia en la plataforma (corridas del job del 08/11 y 09/11/2026)
Una sola cifra por métrica	Los KPIs de Producto, Operaciones Comerciales y Trust & Safety se calculan solo en Gold (`gld_agg_*`). El dashboard y Genie consumen esas tablas.
Reconciliación exacta	400.000 reseñas en Bronze = 373.256 en Silver + 26.744 en cuarentena. Gold publica las 373.256; 372.751 son válidas y 505 quedan marcadas como duplicadas (DQ-002).
Golden record de negocios	14.577 registros de negocio se consolidan en 14.558 negocios maestros: 19 duplicados físicos unificados.
Rating ponderado bayesiano	`gld_agg_business_bayesian_month.bayesian_rating` con m = 25 y C = promedio de la ciudad. Neutraliza negocios con pocas reseñas extremas.
Calidad medida, no supuesta	20 reglas DQ en yelp_gov.dq_rules; 18 cumplen su umbral, ninguna crítica falla y el cumplimiento promedio es 99,53 %. Cada corrida del job queda registrada en yelp_gov.dq_results con las 20 reglas evaluadas.
Privacidad por diseño	Máscara dinámica `yelp_gov.mask_name` sobre `slv_user.name` y `gld_dim_user.name`; solo los grupos `data_stewards` y `trust_and_safety` ven el nombre.

Resultado	Evidencia en la plataforma (corridas del job del 08/11 y 09/11/2026)
Metadata completa	Glosario de 39 términos en 5 dominios y diccionario con las 198 columnas de Silver y Gold. Las 328 columnas de las cuatro capas tienen descripción en Unity Catalog.
Operación automatizada	Job `Pipeline_Medallon_YelpConnect_Grupo03`, diario a las 01:00 UTC, cuatro tareas encadenadas, entre 8 y 9 minutos por corrida.

1.4 Decisiones que se solicitan a la CDO

1. Ratificar a Andrew Collins como Data Owner de Negocio, Categoría, Reseña, Tip y Foto, a Rafael Nakamura de Usuario, Amistad y Cuarentena, y a Carla Romero de Check-in (sección 5).
2. Aprobar la definición de check-in válido implementada (sin duplicado exacto de negocio y fecha-hora) en lugar de la ventana de 60 minutos por usuario, porque el dataset no identifica al usuario del check-in (ADR-01, discrepancia D-03).
3. Firmar la aceptación de riesgo de DQ-008 y DQ-011, que hoy no alcanzan su umbral (sección 6.4).
4. Aprobar el alcance del dashboard (D-11) y el nuevo umbral de duración del pipeline, 10 minutos (D-12).

1.5 Recomendaciones siguientes

1. **Contratos de datos:** acuerdos entre el backend de YelpConnect y la plataforma para que un cambio de esquema no rompa el pipeline en silencio.
2. **Nuevos dominios:** extender la arquitectura a Reservations y Waitlist, reutilizando el identificador maestro de negocio y de usuario.
3. **Analítica de texto:** llevar a operación el análisis de sentimiento y tema de `gld_review_ai_enriched`, hoy una muestra de 500 reseñas, para explicar las causas de insatisfacción.

2 · VISIÓN DE ARQUITECTURA Y SOAW (E1)

Por qué ahora: durante el cierre del segundo trimestre, Producto planificaba rediseñar el algoritmo de recomendación y las insignias de fidelidad, pero se constató que el 14 % de las reseñas de negocios muy bien calificados venía de cuentas duplicadas o no verificadas, y que el conteo de afluencia difería en 28 % de lo reportado a los anunciantes. El comité ejecutivo suspendió el despliegue hasta contar con una arquitectura de datos certificada. Sin ella, Yelp sigue expuesto a fuga de usuarios por recomendaciones inexactas, reclamos de anunciantes por métricas infladas y sanciones por el manejo de datos personales.

2.1 Sponsor

Rol	Persona	Responsabilidad
Sponsor ejecutivo	Laura Hernández, CDO	Financia la iniciativa corporativa de gobierno, aprueba el SoAW y resuelve los conflictos entre áreas.
Sponsor de negocio	Andrew Collins, VP of Product	Define qué significa experiencia de usuario, prioriza las métricas y firma su definición como Data Owner.
Aliada clave	Mei Lin, Director of Data Science	Co-detectó el problema y consume las mismas métricas para los modelos de recomendación.

2.2 Stakeholders

Área y líder	Dolor actual	Qué espera obtener	Tensión con	Rol de gobierno	Prioridad
Producto Andrew Collins	Rating y satisfacción poco confiables; no puede medir la retención real.	Una versión única de la verdad: rating ponderado certificado y engagement confiable.	Operaciones Comerciales, Marketing	Data Owner de Negocio, Categoría, Reseña, Tip y Foto	Alta
Infraestructura y Datos Laura Hernández, CDO	Silos tecnológicos y nadie responde por los datos.	Lakehouse centralizado y gobernado, con RACI formal y seguridad en Unity Catalog.	Todas las áreas	Sponsor ejecutivo; Data Platform actúa como Custodian	Alta
Trust & Safety Rafael Nakamura	No puede auditar el origen de reseñas fraudulentas.	Linaje auditable y cuarentena antes de que una reseña afecte el rating público.	Marketing & Growth	Data Owner de Usuario, Amistad y Cuarentena	Alta
Operaciones Comerciales (Ads) Carla Romero	Conteo inconsistente de check-ins que distorsiona la facturación.	Conteo homologado de check-ins con granularidad temporal clara.	Producto	Data Owner de Check-in	Alta
Data Science Mei Lin	Datasets sin linaje ni metadata; modelos sobre fuentes sin versionar.	Silver y Gold versionados (historial Delta) y con linaje observable.	Infraestructura, Producto	Consumidora; Steward de metadata técnica	Alta
Marketing & Growth Jessica Martínez	Métricas infladas por duplicados de campañas.	Volumen neto de reseñas válidas y usuarios únicos.	Trust & Safety	Consumidora; co-firmante de reseña válida	Media

Tensión principal: Trust & Safety querrá excluir toda reseña sospechosa, mientras Marketing y Operaciones Comerciales quieren volúmenes altos. La solución implementada separa tres conceptos: reseña válida, reseña duplicada (se marca, no se borra) y reseña en cuarentena (se aísla con su motivo).

2.3 Motivadores del negocio

ID	Motivador	Qué se pierde si no se atiende	Quién lo sostiene
MOT-01	**Métricas de producto consolidadas:** una verdad única para la calificación de negocios y la actividad de usuarios.	Usuarios que dejan de confiar en las recomendaciones y caída frente a la competencia.	Andrew Collins
MOT-02	**Accountability y ownership formal** de las entidades maestras.	Nadie responde por la calidad; definiciones huérfanas y disputas interminables.	Laura Hernández
MOT-03	**Depuración de reseñas y check-ins duplicados.**	Pérdida de credibilidad ante los comercios y riesgo de reclamos por cobros inflados.	Carla Romero, Andrew Collins
MOT-04	**Trazabilidad y linaje de extremo a extremo.**	No se pueden defender las cifras ante una auditoría y se degradan los modelos de Data Science.	Rafael Nakamura, Mei Lin
MOT-05	**Eficiencia de cómputo (FinOps)** en un entorno serverless con cuota diaria.	Cuota agotada antes de terminar el pipeline y costos sin control.	Laura Hernández

El dolor, visto en los propios datos

El Yelp Open Dataset muestra la incoherencia sin necesidad de suponerla, y cada diferencia se convirtió en una regla de calidad:

- **Calificación de un negocio:** `business.stars` viene redondeada a medias estrellas, mientras el promedio de las reseñas tiene decimales. La diferencia se publica como `rating_gap` y la mide DQ-007.
- **Número de reseñas:** `business.review_count` es un dato declarado que no coincide con las reseñas de la muestra (DQ-008).
- **Check-ins:** `checkin.date` es un texto con fechas separadas por comas. Silver lo convierte en una fila por fecha-hora y marca los repetidos con `is_duplicate` (DQ-010).

2.4 Alcance

Dimensión	Dentro del alcance	Fuera del alcance y por qué
Datos	Cinco fuentes del Yelp Open Dataset cargadas: business, user, review, tip y checkin, de una sola ciudad (Philadelphia, menos de 300 MB). La red de amistades se modela en `slv_friendship`. La entidad Foto está modelada (`slv_photo`) pero la muestra no incluye photo.json.	Dataset completo y otras ciudades: la cuota de Free Edition no lo soporta. Archivos de imagen.
Métricas	Satisfacción (rating válido y bayesiano), volumen y frescura de reseñas, utilidad, reseñas negativas, engagement (tips y check-ins), retención de cohortes y salud del contenido.	Métricas de uso de la app (sesiones, clics, embudos, DAU/MAU diario): el dataset no tiene eventos de navegación (ADR-12).
Plataforma	Lakehouse bronze → silver → gold con gobierno en `yelp_gov`, sobre Databricks Free Edition y Unity Catalog.	Otras nubes, streaming en tiempo real, conexión directa a bases productivas, clústeres dedicados 24/7.
Gobierno	Glosario, diccionario, 20 reglas DQ con motor y Quality Gate, owners, clasificación, tags, permisos y enmascaramiento de datos personales.	Proceso legal formal de privacidad: se citan las normas pero no se audita su cumplimiento.
Consumo	AI/BI Dashboard (Producto y CDO), Genie Space y vista segura `vw_user_secure`.	Cambios en la app YelpConnect, experimentos A/B, modelos en producción.

Dimensión	Dentro del alcance	Fuera del alcance y por qué
IA (bonus)	Prototipo de sentimiento, tema y consistencia sobre 500 reseñas válidas (`gld_review_ai_enriched`).	Entrenar o desplegar modelos propios de lenguaje.

Regla anti scope creep: una métrica nueva entra solo si se calcula con las entidades del dataset, tiene un owner que la firme y queda registrada en la sección 9.2. Si no cumple las tres condiciones, pasa a trabajo futuro.

2.5 Criterios de éxito

ID	Criterio	Cómo se verifica	Estado	Motivador
CE-01	**Métricas unificadas:** Producto y Operaciones consultan las mismas tablas certificadas de Gold.	Linaje en Unity Catalog; las 14 consultas del E8 (REQ-P0 a REQ-P7 y REQ-G1 a REQ-G6) leen solo yelp_gold y yelp_gov.	Cumplido	MOT-01, MOT-03
CE-02	**Ownership formal:** toda entidad y toda columna tiene Data Owner.	`yelp_gov.raci_matrix` (9 entidades) y `yelp_gov.data_dictionary` (198 columnas) sin owner nulo; el validador de E4 lo comprueba.	Cumplido	MOT-02
CE-03	**Calidad observable:** 20 reglas DQ en cada corrida, ninguna crítica en rojo y cumplimiento promedio ≥ 98,5 %.	`yelp_gov.dq_results`: 99,53 % de promedio y ninguna regla crítica en rojo en las corridas del 08/11 y 09/11/2026; el Quality Gate de 02_silver_limpieza lo verifica en cada corrida.	Cumplido	MOT-03, MOT-04
CE-04	**Protección de datos personales:** el nombre del usuario se enmascara fuera de los roles autorizados.	Column mask `mask_name` activa en `slv_user.name` y `gld_dim_user.name`.	Cumplido	MOT-04
CE-05	**Sostenibilidad FinOps:** el pipeline completo cabe en la cuota diaria y dura menos de 10 minutos.	`Historial del job: 8 min 30 s a 8 min 46 s en las corridas del 08/11 y 09/11/2026 (umbral ajustado en D-12).`	Cumplido	MOT-05
CE-06	**Reconciliación exacta:** ninguna reseña se pierde entre capas.	Control de E6: Bronze = Silver + cuarentena, y Silver = `gld_fact_review` (diferencia 0).	Cumplido	MOT-01, MOT-05
CE-07	**Producto se sirve solo:** Genie responde las preguntas de la sección 7.4 con los sinónimos del glosario.	Demostración en vivo del Genie Space.	Por demostrar	MOT-01
CE-08	**Gobierno visible:** la CDO ve calidad, cobertura de documentación y ownership.	Página Gobierno (CDO) del dashboard (REQ-G1 a REQ-G6).	Cumplido	MOT-02

Las metas son objetivos del proyecto. No existe una línea base histórica de Yelp contra la cual medir la mejora en la experiencia del usuario final.

2.6 Principios de arquitectura

#	Principio	Qué significa en la práctica	Cómo se cumple en la plataforma
P-01	Una métrica, una definición, un dueño	Ninguna métrica llega al dashboard sin estar en el glosario y tener owner.	39 términos en `business_glossary`, todos con propietario.
P-02	Las métricas se calculan solo en Gold	Ninguna área recalcula en su hoja o notebook.	Ocho agregados `gld_agg_*` consumidos por dashboard y Genie.

#	Principio	Qué significa en la práctica	Cómo se cumple en la plataforma
P-03	Bronze es inmutable y fiel al origen	Bronze no se corrige ni se filtra; solo recibe metadata de auditoría.	`_source_file` e `_ingested_at` en las cinco tablas `brz_*`.
P-04	La calidad se mide antes de publicar	Las reglas corren sobre Silver antes de alimentar Gold.	E5 se ejecuta dentro de `02_silver_limpieza` como Quality Gate.
P-05	Una falla de calidad nunca es silenciosa	Una regla que falla se corrige o se acepta como riesgo con firma.	Cada regla tiene acción y responsable en `dq_rules`.
P-06	Mismo diseño en documento y plataforma	Cada notebook declara qué sección implementa.	Matriz de la sección 9 y diagramas tomados de 02-Modelado.
P-07	Privacidad por defecto	Los datos personales se clasifican y se enmascaran.	Tags `classification` y máscara `mask_name`.
P-08	Diseñar para la cuota	Una ciudad, agregados antes de visualizar y bitácora desde el día uno.	Muestra de Philadelphia y `pipeline_run_log`.

2.7 Restricciones y supuestos

Tipo	Enunciado	Impacto en el diseño
Restricción	**Cuota de cómputo serverless:** Databricks Free Edition tiene cuota diaria y un solo metastore.	Muestra de una ciudad, sin `display()` innecesarios y pipelines idempotentes.
Restricción	**Fuentes inmutables:** los esquemas JSON de origen no se pueden cambiar.	Bronze guarda el esquema semiestructurado y Silver tipifica por código.
Restricción	**Claves no forzadas:** Unity Catalog declara PRIMARY KEY y FOREIGN KEY de forma informativa.	La unicidad y la integridad se garantizan con reglas DQ (DQ-001, DQ-003, DQ-006, DQ-012, DQ-016, DQ-018) y el Quality Gate. Las restricciones CHECK sí se aplican.
Supuesto	**Adopción:** las áreas consumen solo desde Gold.	Permisos de lectura sobre `yelp_gold` y `yelp_gov`; Bronze y Silver quedan para el equipo de datos.
Supuesto	**Estabilidad semántica:** el glosario aprobado es el acuerdo institucional.	Cambiar una definición requiere una nueva versión del glosario y su registro en la sección 9.2.

2.8 Roadmap

Fase	Módulos	Entregables para Producto	Estado
Fase 1 · Diseñar	M1-M2	SoAW, estrategia de gobierno, RACI y reglas DQ de reseñas y check-ins.	Completada
Puerta 1: definición de reseña válida firmada por el Data Owner.			
Fase 2 · Definir y modelar	M3-M5	Glosario, golden record, modelos conceptual, lógico y físico, ABB/SBB y permisos.	Completada
Puerta 2: toda métrica del dashboard existe en el glosario y en el DDL.			
Fase 3 · Construir	M6-M8	Pipeline bronze → silver → gold, motor DQ con historial, Auto Loader y bonus de IA.	Completada
Puerta 3: reglas DQ críticas en verde, o riesgo aceptado con firma.			
Fase 4 · Valor y operación	M9-M10	Dashboard de Producto y de la CDO, Genie, job orquestado y bitácora.	Completada; pendiente la demostración de Genie (CE-07)

3 · ARQUITECTURA DE REFERENCIA (E2)

La arquitectura sigue el patrón Lakehouse con capas medallion. Los bloques ABB describen qué capacidad se necesita, sin depender de la tecnología; los SBB son los componentes concretos de Databricks que la implementan.

3.1 Capacidades de negocio

ID	Capacidad	Motivador	Área beneficiada
CAP-01	**Métricas de experiencia consolidadas:** rating, distribución de estrellas y volumen de opiniones con trazabilidad.	MOT-01	Producto, Marketing
CAP-02	**Deduplicación:** detectar reseñas repetidas y check-ins duplicados antes de la analítica.	MOT-03	Producto, Operaciones Comerciales
CAP-03	**Calidad continua:** reglas de integridad, validez y completitud con Quality Gate.	MOT-02, MOT-04	Trust & Safety, CDO
CAP-04	**Protección de datos personales** sin degradar el análisis agregado.	MOT-04	Trust & Safety, Legal
CAP-05	**Versionamiento analítico** con historial Delta y Change Data Feed.	MOT-01, MOT-04	Data Science, Producto
CAP-06	**Autoservicio semántico:** dashboards y preguntas en lenguaje natural sobre datos certificados.	MOT-01, MOT-05	Producto, CDO
CAP-07	**Observabilidad y linaje** desde el JSON hasta el KPI.	MOT-02, MOT-04	Data Platform, Auditoría

3.2 Vista de la arquitectura

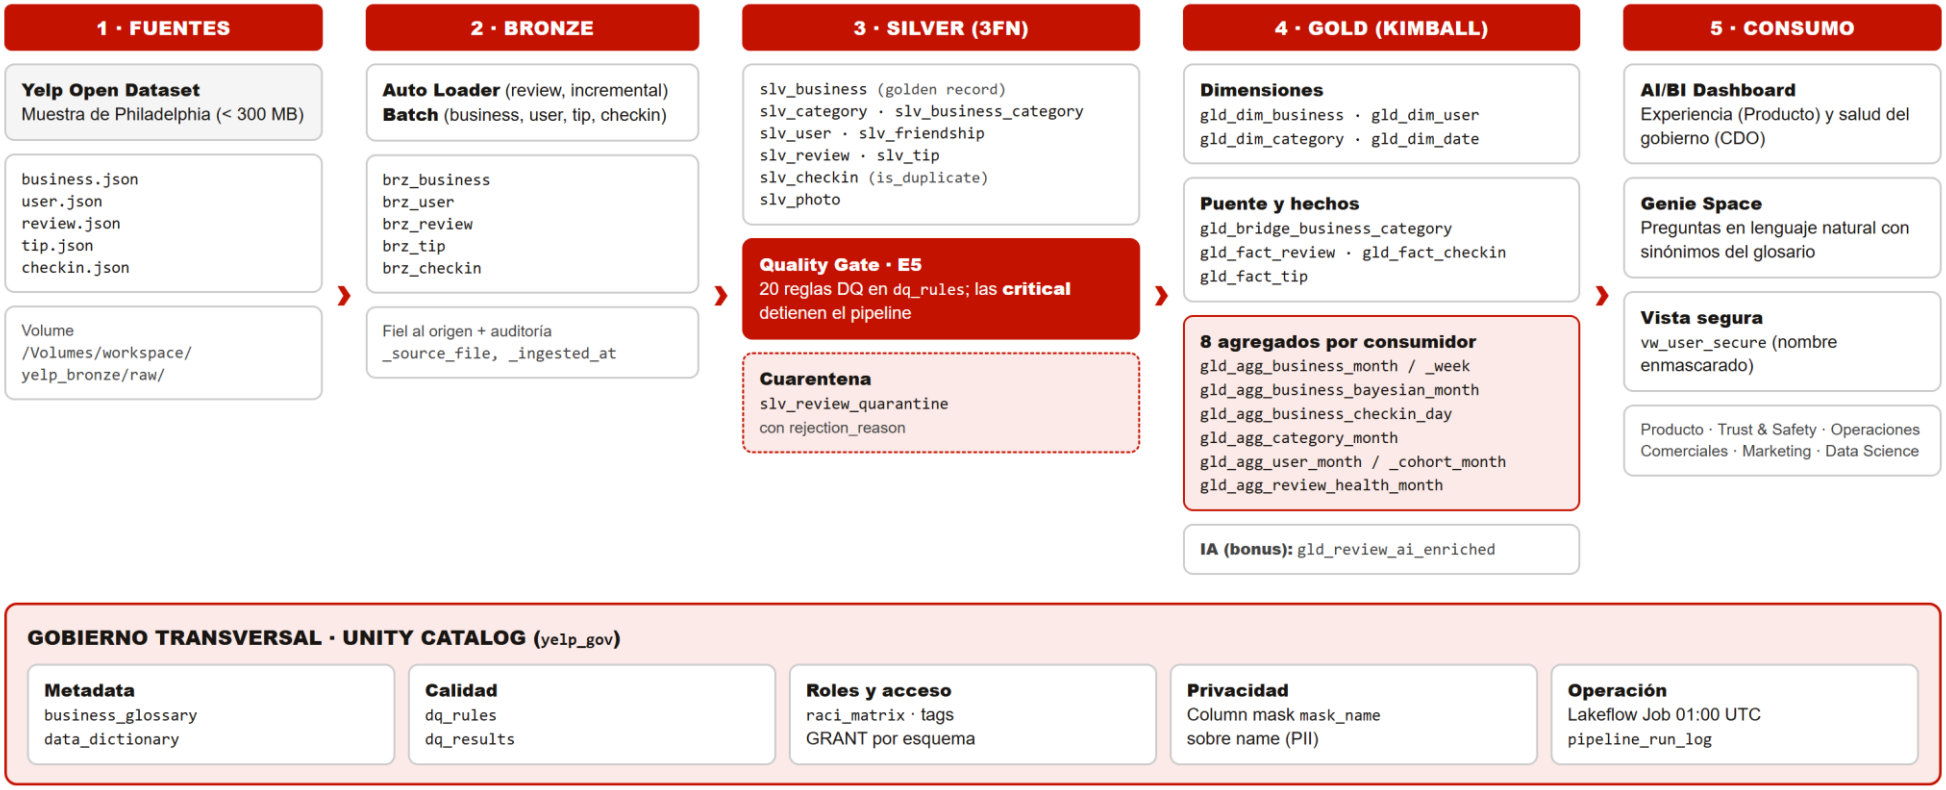


Figura 3.1 · Arquitectura de referencia. Los nombres son los objetos del catálogo `workspace`.

Tres capas horizontales sobre Delta Lake y una franja vertical de gobierno que las cruza. Bronze guarda el JSON tal como llegó, con su archivo de origen y momento de ingesta. Silver tipifica, normaliza en tercera forma normal, unifica los negocios repetidos y aísla en cuarentena las reseñas que incumplen reglas, sin detener el pipeline. Gold publica el modelo dimensional y los agregados que consume Producto.

La franja de gobierno no es una etapa posterior: es un conjunto de metadatos y controles activos en cada capa. Desde ahí se controla el acceso, se enmascara el nombre de los usuarios, se registra el linaje y se ejecutan los Quality Gates. Así, Andrew Collins y su equipo trabajan solo con productos de datos gobernados.

3.3 Bloques de arquitectura (ABB → SBB)

ABB	Capacidad	SBB elegido	Objetos en la plataforma	Alternativas descartadas y por qué
Ingesta idempotente	CAP-02	Auto Loader para review; lectura batch para el resto	`/Volumes/workspace/yelp_bronze/raw/` y su checkpoint	Cargas JDBC directas (bloquean la base productiva); copias manuales (sin detección de archivos nuevos ni evolución de esquema).
Almacenamiento versionado	CAP-01, CAP-05	Tablas Delta en Unity Catalog con Change Data Feed	Esquemas `yelp_bronze`, `yelp_silver`, `yelp_gold`	PostgreSQL (no escala ni versiona); Parquet sin Delta (sin ACID ni MERGE).
Conformación distribuida	CAP-01, CAP-02	PySpark serverless	Notebooks `02_silver_limpieza` y `03_gold_productos_datos`	Pandas en memoria (no escala); procedimientos SQL (sin control de versiones).
Calidad de datos (rules-as-data)	CAP-03	Motor genérico en PySpark como Quality Gate	`yelp_gov.dq_rules`, `yelp_gov.dq_results`	Great Expectations (requiere infraestructura propia); aserciones sueltas en notebooks (sin historial ni auditoría).
Metadata y gobierno	CAP-03, CAP-04, CAP-07	Unity Catalog y tablas de gobierno	COMMENT en el 100 % de columnas, tags, GRANT, `mask_name`, `business_glossary`, `data_dictionary`, `raci_matrix`	Hive Metastore (sin linaje ni tags); DataHub o Atlas (infraestructura adicional).
Orquestación	CAP-01, CAP-03	Lakeflow Jobs	Job `Pipeline_Medallon_YelpConnect_Grupo03`; bitácora `pipeline_run_log`	Airflow dedicado (infraestructura permanente sin justificación de volumen).
Consumo y autoservicio	CAP-06	AI/BI Dashboard y Genie Space	14 consultas E8 (REQ-P0 a REQ-P7, REQ-G1 a REQ-G6) sobre yelp_gold y yelp_gov; vista vw_user_secure	Power BI o Tableau on-premise (gateways, exportación masiva y licencias).

3.4 Decisiones de arquitectura (ADR)

ID	Decisión	Contexto y opciones evaluadas	Motivo de la elección	Estado
ADR-01	Check-in válido = sin duplicado exacto	El origen entrega marcas concatenadas. Se evaluó contar cada marca (Ads), un check-in por día (Producto) y una ventana de 60 minutos por usuario (Acta 01).	El check-in no identifica al usuario, así que una ventana por usuario uniría visitas de personas distintas. El conteo oficial excluye solo los duplicados exactos de negocio y fecha-hora (`is_duplicate`, DQ-010); `active_hour_count` da las horas con actividad como métrica complementaria para Ads.	Vigente; pendiente de firma conjunta Producto–Ads (D-03)
ADR-02	Rating ponderado bayesiano en Gold	Negocios con una sola reseña de 5 estrellas superaban a negocios con cientos. Se evaluó promedio simple frente a media bayesiana.	Media bayesiana con m = 25 y C = promedio de la ciudad en `gld_agg_business_bayesian_month`. Da estabilidad estadística al ranking.	Vigente
ADR-03	Categorías normalizadas con tabla puente	En v0.4 las categorías se guardaron como ARRAY. El modelo lógico vigente exige catálogo propio y relación N:M.	`slv_category` + `slv_business_category` en Silver y `gld_dim_category` + `gld_bridge_business_category` (con `is_primary`) en Gold. Permite métricas por categoría sin explotar arreglos y mantiene la 3FN.	Vigente desde v1.3; reemplaza la decisión de v0.4 (D-01)
ADR-04	Historial Delta para auditoría	Las ediciones y bajas de reseñas borraban el rastro. Se evaluó bitácora manual frente a historial nativo.	`delta.enableChangeDataFeed = true` en todas las tablas de Silver y Gold, más el historial de versiones de Delta (30 días por defecto).	Vigente
ADR-05	Esquema estrella Kimball frente a tabla única (OBT)	Se evaluó una tabla desnormalizada única frente a hechos atómicos y dimensiones conformadas.	Estrella con dimensiones conformadas y agregados por consumidor: análisis flexible por usuario, negocio y tiempo sin duplicar almacenamiento.	Vigente
ADR-06	Enmascaramiento dinámico de PII	Se evaluó anonimizar destructivamente en Silver frente a enmascarar al consultar.	Column mask `workspace.yelp_gov.mask_name`: el dato original se conserva para `data_stewards` y `trust_and_safety`; el resto ve la inicial seguida de ***.	Vigente
ADR-07	`attributes` y `hours` se quedan en Bronze	`attributes` tiene 39 subcampos opcionales, 28 de ellos con más de 65 % de nulos.	Se conservan en `brz_business` (schema-on-read) y no pasan a Silver: ningún requerimiento los usa.	Vigente
ADR-08	Lakehouse medallion en Databricks Free Edition con Unity Catalog	Data warehouse clásico; data lake sin capas; Snowflake o BigQuery.	Plataforma del programa. Separa fidelidad, limpieza y consumo, y une permisos, tags, linaje y metadata junto al dato.	Aceptada (restricción)
ADR-09	Reglas DQ como datos con motor genérico	Reglas dentro de cada notebook.	El Steward cambia umbrales sin tocar código y cada corrida queda en el historial.	Vigente
ADR-10	Muestra de una sola ciudad	Dataset completo (10 GB).	La cuota diaria no soporta el volumen completo; Philadelphia basta para demostrar la arquitectura.	Vigente
ADR-11	Auto Loader solo sobre review	Recarga completa diaria de todas las entidades.	Review es la entidad de mayor volumen; procesar solo lo nuevo	Vigente

ID	Decisión	Contexto y opciones evaluadas	Motivo de la elección	Estado
			ahorra cuota y demuestra idempotencia.	
ADR-12	Experiencia medida con contenido y engagement	Métricas de uso de la app.	El dataset no tiene eventos de navegación; la limitación se declara (DAU/MAU queda fuera de alcance).	Aceptada
ADR-13	Golden record de negocios	Publicar cada `business_id` tal como llega.	`master_business_id` une los registros con el mismo nombre, dirección y código postal normalizados; sobrevive el de más reseñas. Gold publica solo el maestro (DQ-012).	Vigente
ADR-14	Gold con claves naturales y estado vigente	Claves sustitutas y SCD tipo 2 (diseño v1.1).	Las dimensiones usan el identificador de Yelp (`business_key`, `user_key`, `category_key`) y `date_key` YYYYMMDD. El historial lo da el Change Data Feed (ADR-04).	Vigente desde v1.3 (D-02)
ADR-15	Nombres técnicos en inglés	Nombres en español.	Tablas y columnas en inglés en las cuatro capas, como el modelo lógico; descripciones y metadata en español.	Vigente desde v1.3 (D-07)

4 · MODELO DE DATOS (E3)

El modelo parte de las entidades del Yelp Open Dataset. Negocio y Reseña son el centro porque de ellos salen las métricas de experiencia; el resto aporta engagement y contexto. Los tres diagramas de esta sección se generan desde los archivos de `02-Modelado`, la fuente de verdad del modelo.

4.1 Modelo conceptual

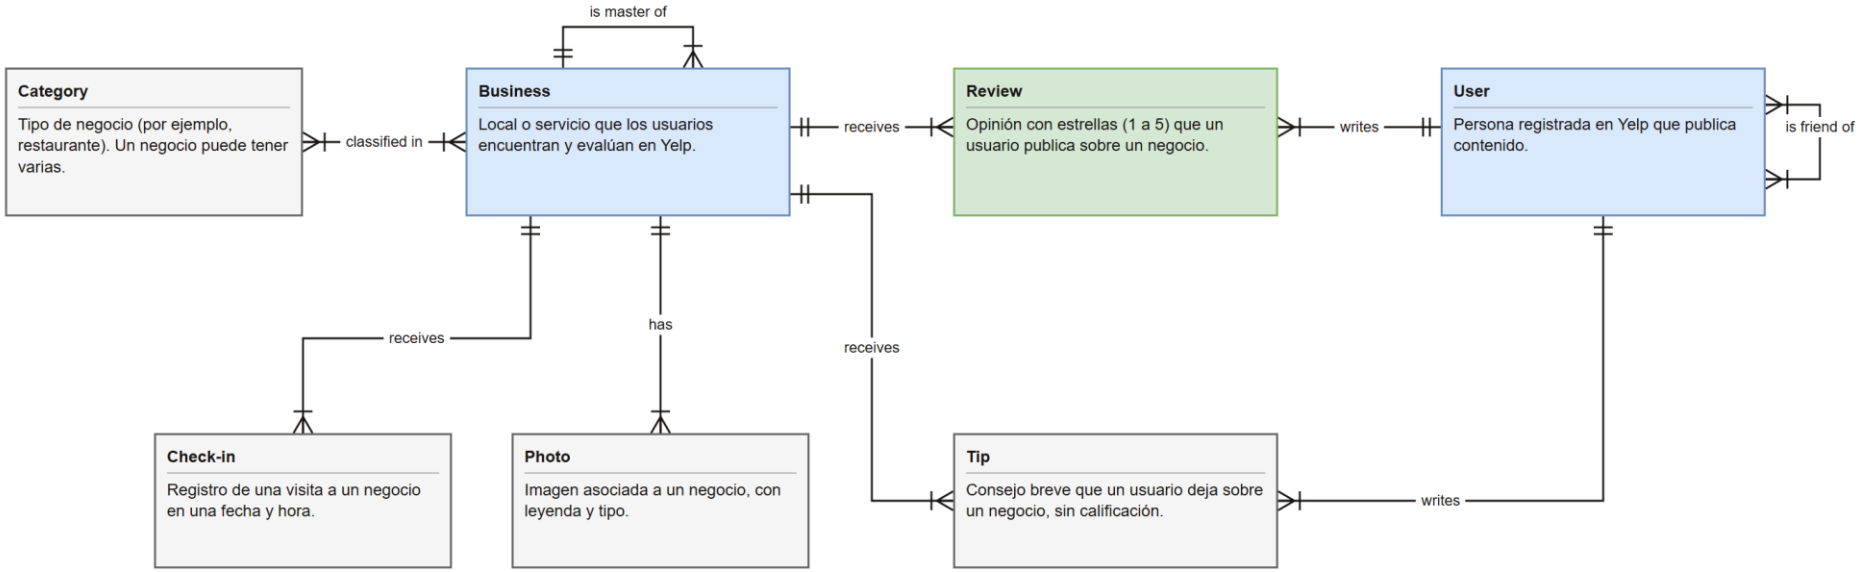


Figura 4.1 · Modelo conceptual (`yelp_modelo_conceptual.drawio`).

Entidad	Definición de negocio	Dominio	Relaciones principales
Business (Negocio)	Local o servicio que los usuarios encuentran y evalúan en Yelp.	Negocio	Recibe reseñas, tips y check-ins; tiene fotos; se clasifica en categorías; es maestro de sus duplicados.
Category (Categoría)	Tipo de negocio, como restaurante o cafetería. Un negocio puede tener varias.	Negocio	N:M con Negocio.
User (Usuario)	Persona registrada en Yelp que publica contenido.	Usuario	Escribe reseñas y tips; es amigo de otros usuarios (N:M).
Review (Reseña)	Opinión con estrellas (1 a 5) que un usuario publica sobre un negocio.	Contenido	Pertenece a un usuario y a un negocio.
Tip	Consejo breve que un usuario deja sobre un negocio, sin calificación.	Contenido	Pertenece a un usuario y a un negocio.
Check-in	Registro de una visita a un negocio en una fecha y hora.	Interacción	Pertenece a un negocio; no identifica al usuario.
Photo (Foto)	Imagen asociada a un negocio, con leyenda y tipo.	Contenido	Pertenece a un negocio. Modelada; la muestra no la incluye.

4.2 Modelo lógico de la capa Silver

Silver está en tercera forma normal: cada tabla tiene un grano único, las relaciones N:M se resuelven con tablas puente y los datos rechazados quedan aislados. Las claves primarias y foráneas se declaran en Unity Catalog; las restricciones CHECK (por ejemplo, estrellas entre 1 y 5 y `user_id_1 < user_id_2`) se aplican en la escritura.

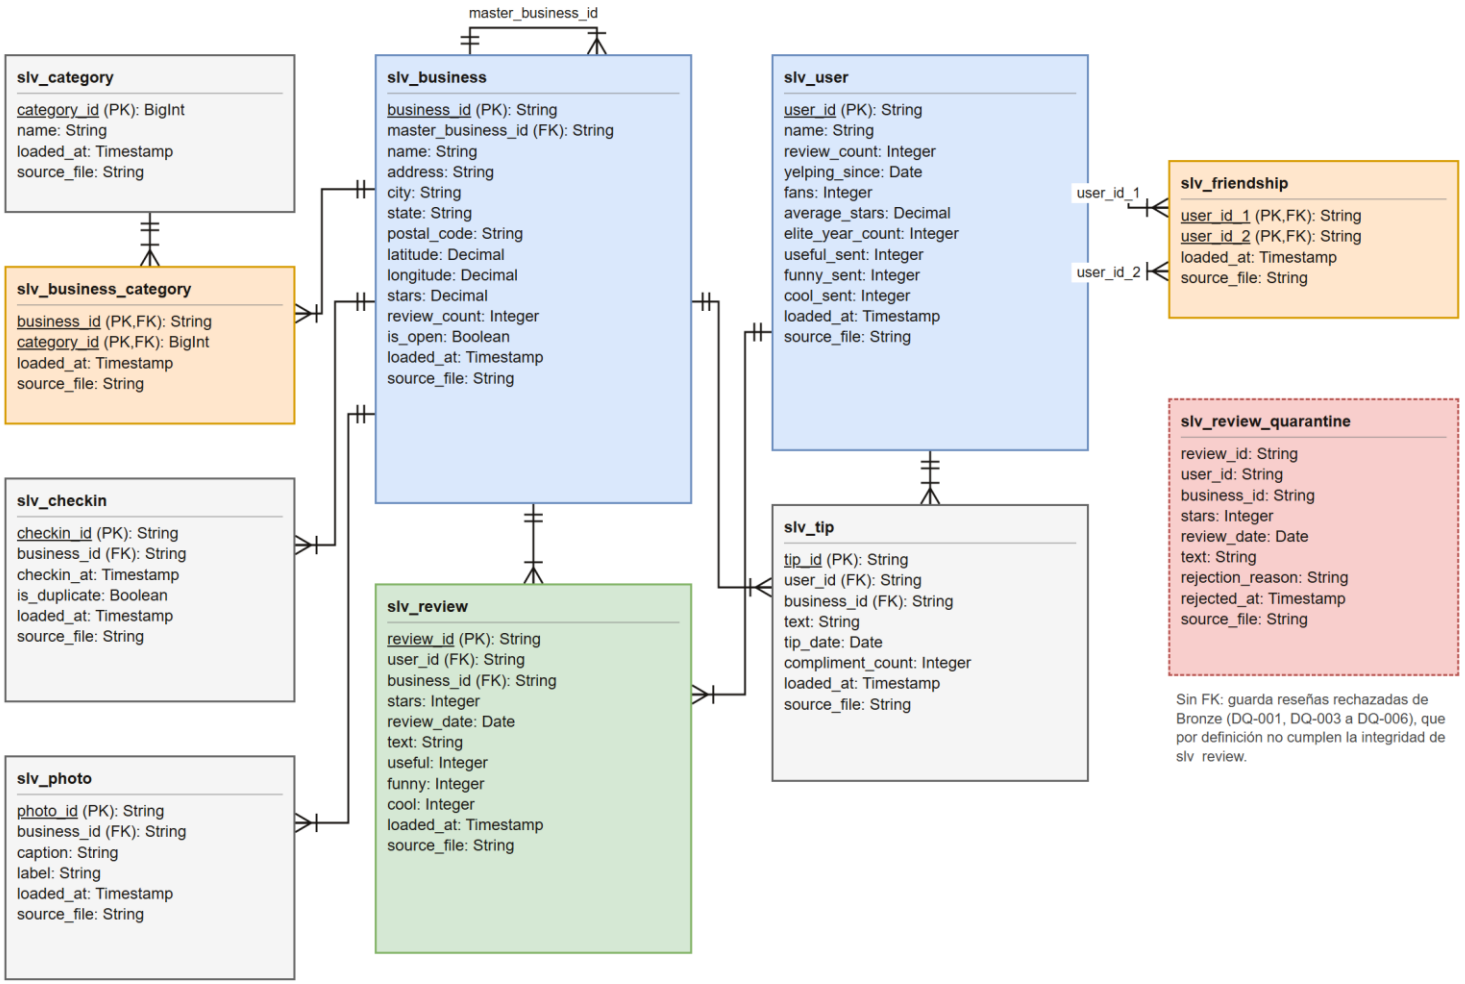


Figura 4.2 · Modelo lógico Silver (`yelp_modelo_logico.drawio`, página Silver; DDL en `yelp_silver.txt`).

Tabla	Grano	Clave primaria	Claves foráneas	Columnas
slv_business	Una fila por negocio.	business_id	master_business_id → slv_business	business_id, master_business_id, name, address, city, state, postal_code, latitude, longitude, stars, review_count, is_open, loaded_at, source_file
slv_category	Una fila por categoría.	category_id	–	category_id, name, loaded_at, source_file
slv_business_category	Una fila por par negocio-categoría.	business_id + category_id	business_id → slv_business category_id → slv_category	business_id, category_id, loaded_at, source_file
slv_user	Una fila por usuario.	user_id	–	user_id, name, review_count, yelping_since, fans, average_stars, elite_year_count, useful_sent, funny_sent, cool_sent, loaded_at, source_file
slv_friendship	Una fila por amistad (el par se guarda una sola vez, con user_id_1 < user_id_2).	user_id_1 + user_id_2	user_id_1 → slv_user user_id_2 → slv_user	user_id_1, user_id_2, loaded_at, source_file
slv_review	Una fila por reseña.	review_id	business_id → slv_business user_id → slv_user	review_id, user_id, business_id, stars, review_date, text, useful, funny, cool, loaded_at, source_file
slv_review_quarantine	Una fila por reseña rechazada.	– (sin PK: auditoría)	–	review_id, user_id, business_id, stars, review_date, text, rejection_reason, rejected_at, source_file
slv_tip	Una fila por tip.	tip_id	business_id → slv_business user_id → slv_user	tip_id, user_id, business_id, text, tip_date, compliment_count, loaded_at, source_file
slv_checkin	Una fila por cada fecha-hora de la lista original.	checkin_id	business_id → slv_business	checkin_id, business_id, checkin_at, is_duplicate, loaded_at, source_file
slv_photo	Una fila por foto.	photo_id	business_id → slv_business	photo_id, business_id, caption, label, loaded_at, source_file

Decisiones de normalización

1. **Golden record:** se normalizan nombre, dirección y código postal; los registros que coinciden comparten `master_business_id` y sobrevive el de más reseñas declaradas (ADR-13).
2. **Categorías:** catálogo `slv_category` y puente `slv_business_category` (ADR-03).
3. **Red social:** `slv_friendship` guarda cada par una sola vez, con `user_id_1 < user_id_2`. Los votos que el usuario envía quedan en `useful_sent`, `funny_sent` y `cool_sent` de `slv_user`.
4. **Check-ins a grano evento:** una fila por fecha-hora de la lista original, con `is_duplicate` para los repetidos (ADR-01).

5. **Cuarentena:** `slv_review_quarantine` no tiene claves foráneas a propósito: guarda las reseñas rechazadas, que por definición no cumplen la integridad de `slv_review`.

Relaciones y cardinalidades

Padre	Hijo (clave foránea)	Cardinalidad	Control de integridad
`slv_business.business_id`	`slv_business.master_business_id`	1 : N	DQ-012
`slv_business.business_id`	`slv_business_category.business_id`	1 : N	DQ-018
`slv_category.category_id`	`slv_business_category.category_id`	1 : N	DQ-018
`slv_user.user_id`	`slv_friendship.user_id_1`	1 : N	CHECK user_id_1 < user_id_2
`slv_user.user_id`	`slv_friendship.user_id_2`	1 : N	CHECK user_id_1 < user_id_2
`slv_business.business_id`	`slv_review.business_id`	1 : N	DQ-006
`slv_user.user_id`	`slv_review.user_id`	1 : N	DQ-003, DQ-016
`slv_business.business_id`	`slv_tip.business_id`	1 : N	DQ-020
`slv_user.user_id`	`slv_tip.user_id`	1 : N	DQ-020
`slv_business.business_id`	`slv_checkin.business_id`	1 : N	DQ-010
`slv_business.business_id`	`slv_photo.business_id`	1 : N	–

4.3 Modelo dimensional de la capa Gold (Kimball)

Gold usa un modelo estrella con dimensiones conformadas: todas las métricas comparten la misma definición de negocio, usuario, categoría y fecha. Cada tabla declara su grano en el comentario de Unity Catalog, y los hechos atómicos viven separados de los agregados para evitar dobles conteos.

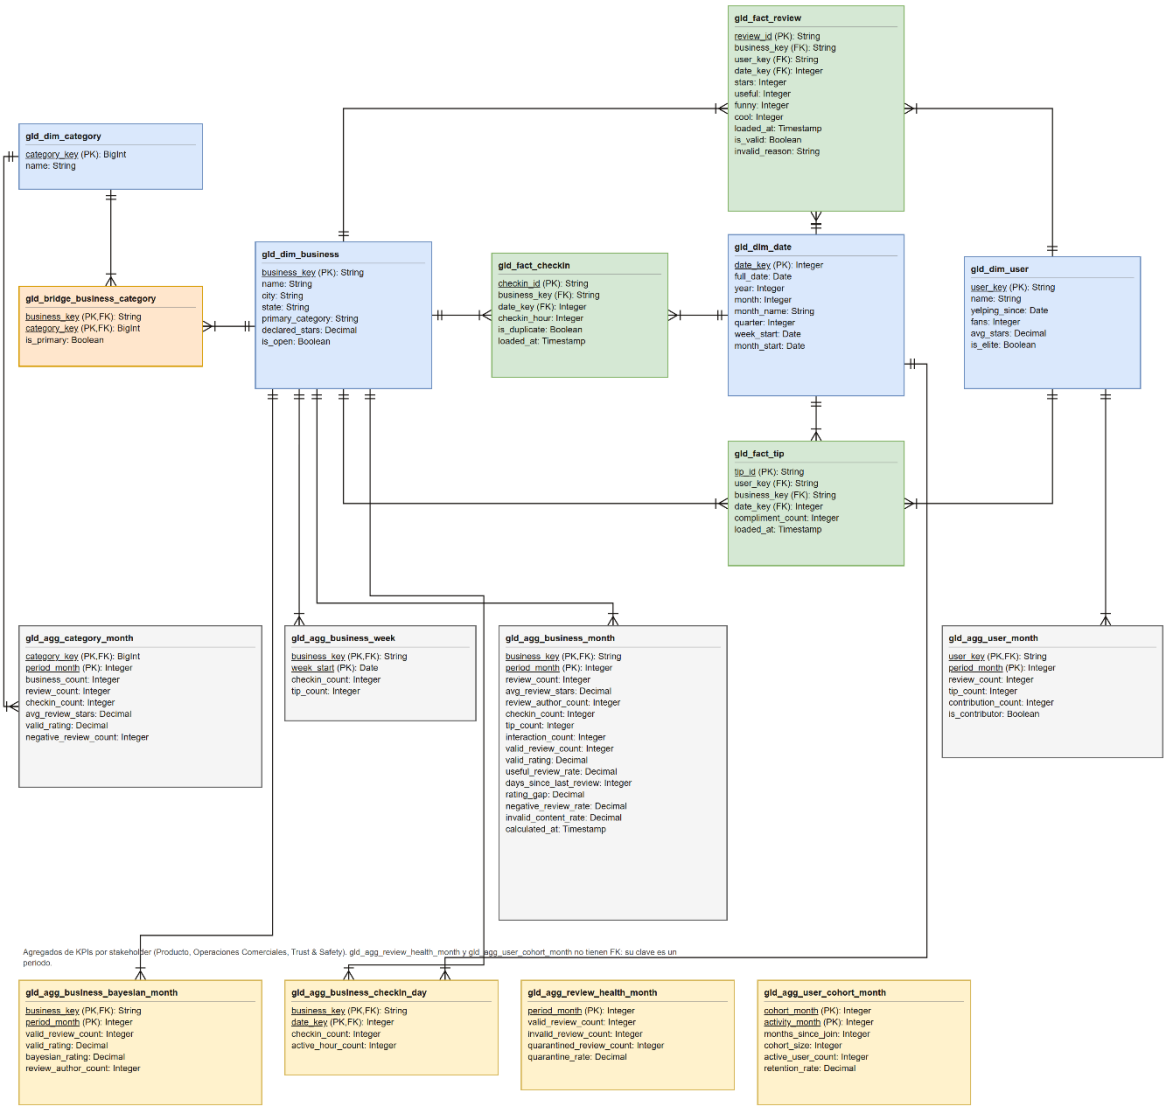


Figura 4.3 · Modelo dimensional Gold (`yelp_modelo_logico.drawio`, página Gold; DDL en `yelp_gold.txt`).

Tabla	Tipo	Grano	Clave primaria	Claves foráneas
`gld_dim_business`	Dimensión	Una fila por negocio maestro (golden record).	business_key	–
`gld_dim_user`	Dimensión	Una fila por usuario.	user_key	–
`gld_dim_category`	Dimensión	Una fila por categoría.	category_key	–
`gld_dim_date`	Dimensión	Una fila por día.	date_key	–
`gld_bridge_business_category`	Puente	Una fila por par negocio-categoría.	business_key + category_key	`business_key` → `gld_dim_business` `category_key` → `gld_dim_category`
`gld_fact_review`	Hecho atómico	Una fila por reseña publicada.	review_id	`business_key` → `gld_dim_business` `date_key` → `gld_dim_date` `user_key` → `gld_dim_user`

Tabla	Tipo	Grano	Clave primaria	Claves foráneas
gld_fact_checkin	Hecho atómico	Una fila por check-in.	checkin_id	business_key → gld_dim_business date_key → gld_dim_date
gld_fact_tip	Hecho atómico	Una fila por tip.	tip_id	business_key → gld_dim_business date_key → gld_dim_date user_key → gld_dim_user
gld_agg_business_month	Agregado	Una fila por negocio y mes.	business_key + period_month	business_key → gld_dim_business
gld_agg_business_week	Agregado	Una fila por negocio y semana.	business_key + week_start	business_key → gld_dim_business
gld_agg_business_bayesian_month	Agregado	Una fila por negocio y mes.	business_key + period_month	business_key → gld_dim_business
gld_agg_business_checkin_day	Agregado	Una fila por negocio y día con check-ins.	business_key + date_key	business_key → gld_dim_business date_key → gld_dim_date
gld_agg_category_month	Agregado	Una fila por categoría y mes.	category_key + period_month	category_key → gld_dim_category
gld_agg_user_month	Agregado	Una fila por usuario y mes.	user_key + period_month	user_key → gld_dim_user
gld_agg_user_cohort_month	Agregado	Una fila por cohorte y mes de actividad.	cohort_month + activity_month	–
gld_agg_review_health_month	Agregado	Una fila por mes.	period_month	–

Además del modelo, Gold expone la vista vw_user_secure (usuarios con nombre enmascarado) y la tabla del bonus de IA gld_review_ai_enriched.

4.4 Trazabilidad conceptual → lógico → físico

Entidad conceptual	Silver	Gold	Clave
Business	slv_business	gld_dim_business	business_id → business_key (negocio maestro)
Category	slv_category, slv_business_category	gld_dim_category, gld_bridge_business_category	category_id → category_key
User	slv_user, slv_friendship	gld_dim_user	user_id → user_key
Review	slv_review, slv_review_quarantine	gld_fact_review	review_id
Tip	slv_tip	gld_fact_tip	tip_id
Check-in	slv_checkin	gld_fact_checkin	checkin_id
Photo	slv_photo	No se publica en Gold (sin datos en la muestra)	photo_id

Entidad conceptual	Silver	Gold	Clave
Calendario	—	`gld_dim_date`	`date_key` (YYYYMMDD)

5 · ESTRATEGIA DE GOBIERNO Y MATRIZ RACI (E6)

El gobierno resuelve el problema de fondo del caso: nadie respondía por los datos. La estrategia asigna un dueño a cada entidad, clasifica cada columna y define quién decide qué, siguiendo DAMA-DMBOK 2.

5.1 Roles de gobierno

Rol	Qué hace	Quién lo ejerce en YelpConnect
Patrocinador del gobierno	Aprueba políticas, arbitra conflictos entre áreas y responde ante la dirección.	Laura Hernández, CDO
Data Owner	Responde por el significado, la clasificación, la calidad aceptable y el uso de los datos de su dominio; aprueba definiciones y asume riesgos residuales.	Andrew Collins: Negocio, Categoría, Reseña, Tip y Foto · Rafael Nakamura: Usuario, Amistad y Cuarentena · Carla Romero: Check-in
Data Steward	Define reglas de calidad, mantiene glosario y diccionario, verifica el linaje y decide qué hacer cuando una regla falla.	Stewards de Producto, de Trust & Safety, de Privacidad y de Interacción Comercial; Mei Lin como Steward de metadata técnica
Data Custodian	Opera la plataforma, aplica permisos y ejecuta el pipeline.	Data Platform (Grupo 03), bajo la CDO
Data Consumer	Usa los productos de datos según sus permisos.	Producto, Marketing & Growth, Data Science, Operaciones Comerciales, Trust & Safety

5.2 Matriz RACI por entidad

La matriz se registra en `workspace.yelp_gov.raci_matrix` y la carga el notebook E6 en cada corrida del job. La tabla siguiente es su contenido.

Entidad y tablas	Dominio	Data Owner (A)	Data Steward (R)	Data Custodian	Consumidores (I)	Clasificación
Negocio `slv_business / gld_dim_business`	Negocio	Andrew Collins (VP of Product)	Steward de Producto	Data Platform (Grupo 03)	Producto, Operaciones Comerciales, Marketing, Analítica BI	Público
Categoría `slv_category / slv_business_category / gld_dim_category / gld_bridge_business_category`	Negocio	Andrew Collins (VP of Product)	Steward de Producto	Data Platform (Grupo 03)	Producto, Marketing, Analítica BI	Público
Reseña `slv_review / gld_fact_review`	Contenido	Andrew Collins (VP of Product)	Steward de Producto y Steward de Trust & Safety	Data Platform (Grupo 03)	Producto, Trust & Safety, Marketing, CDO	Interno
Cuarentena de reseñas `slv_review_quarantine / gld_agg_review_health_month`	Confianza y Seguridad	Rafael Nakamura (Lead Trust & Safety)	Steward de Trust & Safety	Data Platform (Grupo 03)	Trust & Safety, CDO (Laura Hernández), Producto	Confidencial
Usuario `slv_user / gld_dim_user`	Usuario	Rafael Nakamura	Steward de Privacidad	Data Platform	Trust & Safety (acceso PII), Producto y	Restringido (PII)

Entidad y tablas	Dominio	Data Owner (A)	Data Steward (R)	Data Custodian	Consumidores (I)	Clasificación
		(Lead Trust & Safety)	y Protección de Datos	(Grupo 03)	Marketing (solo enmascarado)	
Amistad `slv_friendship`	Interacción / Red	Rafael Nakamura (Lead Trust & Safety)	Steward de Privacidad y Producto	Data Platform (Grupo 03)	Producto (engagement comunitario), Trust & Safety (detección de anillos de bots)	Interno
Check-in `slv_checkin` / `gld_fact_checkin` / `gld_agg_business_checkin_day`	Interacción y Publicidad	Carla Romero (Head of Commercial Ops & Ads)	Steward de Interacción Comercial	Data Platform (Grupo 03)	Operaciones Comerciales (Yelp Ads), Producto (Andrew Collins)	Confidencial
Tip `slv_tip` / `gld_fact_tip`	Contenido	Andrew Collins (VP of Product)	Steward de Producto	Data Platform (Grupo 03)	Producto, Experiencia de Usuario, Trust & Safety	Público
Foto `slv_photo`	Contenido	Andrew Collins (VP of Product)	Steward de Producto	Data Platform (Grupo 03)	Producto, Marketing	Público

5.3 Matriz RACI por actividad

R = realiza · A = aprueba y responde · C = consultado · I = informado. Una sola A por actividad.

Actividad	CDO	Producto	Trust & Safety	Marketing	Data Science	Op. Comerciales	Data Platform
Aprobar alcance y SoAW	A	C	I	I	I	I	R
Definir métricas de experiencia	I	A	C	C	C	C	R
Definir reseña válida	I	A	R	C	I	C	C
Definir check-in válido	I	C	I	I	I	A	R
Fijar umbrales de reglas DQ	I	A	R	I	C	C	C
Aceptar un riesgo de calidad	I	A	R	I	I	I	I
Clasificar datos y PII	A	C	R	I	I	I	C
Otorgar permisos por rol	A	I	C	I	I	I	R
Mantener glosario y diccionario	A	C	R	C	C	C	I
Operar pipeline y job	I	I	I	I	I	I	A/R
Versionar datasets para modelos	I	C	I	I	A/R	I	C
Resolver conflictos de definición	A	C	C	C	C	C	R

5.4 Política de clasificación

Cada nivel se aplica como tag `classification` en Unity Catalog, a partir de la columna Sensibilidad del diccionario (notebook E4) y de los controles de E6.

Nivel	Tag	Definición	Ejemplos en YelpConnect	Control aplicado	Columnas
Público	`public`	Información que Yelp ya muestra a cualquier visitante.	Nombre, dirección y categorías del negocio; calificación publicada.	Lectura para todos los roles.	124
Interno	`internal`	Uso interno de colaboradores, sin datos personales.	Métricas Gold, conteos de check-ins, coordenadas, metadata de carga.	Lectura para roles internos.	55
Confidencial	`confidential`	Ligada a un usuario de forma indirecta o sensible para el negocio.	Texto de reseñas, cuarentena, check-ins de Ads.	Acceso por rol; uso agregado en Gold.	16
Restringido (PII)	`restricted`	Dato personal que identifica directamente a una persona.	Nombre del usuario (`name`).	Column mask `mask_name`; tag `confidentiality = PII`.	3

Columnas: cantidad de columnas de Silver y Gold con cada nivel en `yelp_gov.data_dictionary`. Retención según el diccionario: 36 meses tras la baja de la cuenta para datos de usuario, 5 años en capa activa para contenido y 60 meses para indicadores de negocio; cada Data Owner la ratifica.

5.5 Marco normativo

Norma	Qué exige sobre los datos del caso	Dónde se cumple en la plataforma
RGPD (UE) 2016/679	Minimización (art. 5) y derecho de supresión (art. 17).	Solo se promueven a Silver los atributos que usa algún requerimiento (ADR-07); nombre enmascarado; supresión posible con DELETE/MERGE sobre Delta.
CCPA / CPRA (California)	No vender datos personales sin consentimiento; transparencia sobre los datos retenidos.	Permisos en Unity Catalog; los consumidores de negocio solo ven el nombre enmascarado.
Ley N.° 29733 (Perú)	Consentimiento y seguridad en el tratamiento de datos personales.	Esquemas gobernados, clasificación por columna y bitácora de ejecuciones en `pipeline_run_log`.
Políticas internas de Yelp	Las reseñas en cuarentena no se usan con fines comerciales.	Las reseñas rechazadas quedan en `slv_review_quarantine` y no llegan a los hechos de Gold.

5.6 Mecanismos de control y toma de decisiones

Tipo de decisión	Propone	Aprueba	Se registra en
Definición de una métrica	Analista de BI y Valor	Data Owner de la métrica	Glosario (`business_glossary`) y sección 9.2
Umbral de una regla de calidad	Data Steward	Data Owner de la entidad	`dq_rules`, con su justificación (`threshold_rationale`)
Aceptar un riesgo de calidad	Data Steward	Data Owner, con firma	Sección 9.2 y `failure_action`
Cambio de diseño	Arquitecto de datos	Equipo; la CDO si cambia el alcance	Nuevo ADR y sección 9.2
Conflicto entre áreas	Cualquier área	CDO	Sección 9.2

Gestión de excepciones de acceso

1. **Solicitud:** quien necesita un acceso temporal o un cambio de regla lo pide al Data Steward del dominio, con propósito y duración.
2. **Alternativas (24 horas):** el Steward verifica si una tabla o vista de Gold ya cubre la necesidad sin exponer datos en crudo. Si existe, se usa esa y se cierra la solicitud.
3. **Aprobación (48 horas):** si no hay alternativa, decide el Data Owner del dominio.
4. **Caducidad:** toda excepción aprobada vence en 30 días como máximo y se revoca.

Controles permanentes: rama `main` revisada antes de cada commit, matriz de trazabilidad actualizada en cada checkpoint, Quality Gate antes de publicar Gold y mínimo privilegio con PII enmascarada.

6 · REGLAS DE CALIDAD EN LENGUAJE DE NEGOCIO (E5)

Las reglas se escriben para que las entienda alguien de Marketing. Cada una tiene dimensión, criticidad, un umbral justificado, una acción si falla y un responsable. Viven como datos en `workspace.yelp_gov.dq_rules` y un motor genérico las evalúa en cada corrida (ADR-09).

6.1 Dimensiones de calidad

Dimensión	Pregunta que responde	Reglas
Completitud	¿Está todo el dato que debería estar?	DQ-003, DQ-011, DQ-017
Unicidad	¿Cada cosa existe una sola vez?	DQ-001, DQ-002, DQ-010, DQ-012, DQ-019
Validez	¿El dato respeta el formato y el rango permitido?	DQ-004, DQ-005, DQ-009
Consistencia	¿Dos datos que deberían coincidir coinciden?	DQ-006, DQ-007, DQ-008, DQ-014, DQ-016, DQ-018, DQ-020
Exactitud	¿El dato refleja la realidad?	DQ-013
Oportunidad	¿El dato está al día cuando se usa?	DQ-015

6.2 Catálogo de reglas

Las reglas DQ-001 a DQ-015 son las que citan los comentarios del modelo (`yelp_silver.txt` y `yelp_gold.txt`). DQ-016 a DQ-020 provienen del diccionario de datos revisado por el equipo.

ID	Entidad	Regla en lenguaje de negocio	Dimensión	Criticidad	Umbral	Por qué ese umbral
DQ-001	Reseña	Cada reseña tiene identificador y aparece una sola vez (review_id único)	Unicidad	Crítica	100 %	review_id es la clave primaria de la reseña. Una reseña repetida infla el volumen y altera el rating bayesiano de Producto. No hay margen aceptable: si falla, el defecto está en la deduplicación de silver.
DQ-002	Reseña	Un usuario no publica el mismo texto dos veces sobre el mismo negocio. Las repetidas se marcan como no válidas en Gold (is_valid = false) y no bloquean la carga	Unicidad	Alta	99.5 %	Los textos repetidos del mismo usuario sobre el mismo negocio son reenvíos o spam de campaña. Se tolera hasta 0,5 % porque no bloquean la carga: Gold los excluye con is_valid = false. Un valor mayor sugiere una campaña coordinada.
DQ-003	Reseña	Toda reseña tiene autor, negocio, estrellas y fecha	Completitud	Crítica	100 %	Sin autor, negocio, estrellas o fecha, la reseña no puede entrar en ningún KPI de Producto: rating, usuarios activos ni tendencia mensual.
DQ-004	Reseña	Las estrellas son un número entero de 1 a 5	Validez	Crítica	100 %	Yelp solo permite calificaciones enteras de 1 a 5. Un valor fuera de esa escala distorsiona el rating bayesiano y cualquier promedio.
DQ-005	Reseña	La fecha de la reseña no es futura ni	Validez	Alta	100 %	Yelp se fundó en 2004 y una reseña no puede tener fecha futura. Una fecha imposible coloca la reseña en

ID	Entidad	Regla en lenguaje de negocio	Dimensión	Criticidad	Umbral	Por qué ese umbral
		anterior a 2004, año de fundación de Yelp				el mes equivocado y altera las tendencias mensuales y las cohortes.
DQ-006	Reseña	Toda reseña corresponde a un negocio existente en la muestra	Consistencia	Crítica	100 %	Una reseña sin negocio en la muestra no puede asignarse a ningún rating. Es una regla de guarda: la carga ya filtra por negocios de Philadelphia, y la regla confirma que ese filtro siguió funcionando.
DQ-007	Negocio	La calificación declarada del negocio no difiere en más de 0,5 estrellas del promedio de sus reseñas	Consistencia	Media	90 %	Las estrellas declaradas por Yelp vienen redondeadas a medias estrellas y la muestra no incluye todas las reseñas históricas, así que una diferencia moderada es esperable. El 10 % tolerado corresponde a negocios con pocas reseñas en la muestra: es el mismo problema que corrige el rating bayesiano (m = 25).
DQ-008	Negocio	Las reseñas presentes en la muestra no superan las reseñas declaradas del negocio	Consistencia	Media	98 %	La muestra solo puede contener una parte de las reseñas declaradas por el negocio. Se toleran 2 % de excepciones porque Yelp actualiza review_count en otro momento que la exportación de reseñas. Más que eso indica reseñas duplicadas o asignadas al negocio equivocado.
DQ-009	Check-in	Cada fecha de check-in tiene formato de fecha y hora válido (las inválidas se descartan al cargar)	Validez	Alta	100 %	Es una regla de guarda: las fechas ilegibles se descartan al convertir la lista de texto del JSON. Después de esa conversión no debería quedar ninguna fecha nula o fuera de rango; cualquier fallo indica que la conversión cambió. Por eso el umbral pasa de 99,9 a 100.
DQ-010	Check-in	Check-in válido: no se cuentan dos marcas del mismo negocio con exactamente la misma fecha y hora (duplicado técnico). Los repetidos quedan con is_duplicate = true	Unicidad	Alta	99 %	Las marcas idénticas son reenvíos técnicos del registro. Se tolera 1 % porque se excluyen del conteo sin perder datos; un valor mayor indica un problema en la fuente. Como el check-in no identifica al usuario, agrupar por ventana de 60 minutos uniría visitas de personas distintas: por eso el conteo oficial (checkin_count) usa fecha y hora exactas y las horas con actividad (active_hour_count) quedan como métrica complementaria para Ads. Pendiente de aprobación conjunta de Producto y Ads.
DQ-011	Negocio	Todo negocio tiene nombre, dirección, ciudad y coordenadas	Completitud	Alta	98 %	Producto necesita nombre y ubicación para mostrar el negocio y ubicarlo en el mapa. Se tolera 2 % porque Yelp registra negocios sin dirección física, como servicios a domicilio; esos se excluyen solo de los visuales geográficos.

ID	Entidad	Regla en lenguaje de negocio	Dimensión	Criticidad	Umbral	Por qué ese umbral
DQ-012	Negocio	Un mismo negocio físico tiene un solo identificador maestro (golden record)	Unicidad	Alta	99 %	El golden record debe asignar un solo master_business_id por negocio físico. Se tolera 1 % porque sucursales legítimas pueden compartir nombre y dirección, por ejemplo en un centro comercial.
DQ-013	Negocio	Las coordenadas del negocio caen dentro del área de Philadelphia, la ciudad muestreada	Exactitud	Media	99 %	La muestra corresponde solo a Philadelphia. Coordenadas fuera del área indican un error de geocodificación. Se tolera 1 % para negocios en el límite del área metropolitana.
DQ-014	Usuario	La fecha de alta del usuario no es posterior a su primera reseña	Consistencia	Media	99 %	Un usuario no puede reseñar antes de registrarse. Se tolera 1 % por diferencias de zona horaria entre la fecha de alta y la de la reseña. Afecta el cálculo de cohortes de Producto.
DQ-015	Reseña	Silver incluye la última carga de Bronze (los datos publicados no están atrasados)	Oportunidad	Alta	100 %	Si silver no incluye la última carga, el dashboard muestra datos atrasados. Se evalúa sobre la tabla completa y no fila por fila, para que funcione con ingesta incremental: el resultado es 100 % o 0 %.
DQ-016	Reseña	Toda reseña corresponde a un usuario existente	Consistencia	Crítica	100 %	Sin un autor existente no se puede contar al usuario activo ni ubicarlo en su cohorte. Se separó de DQ-003 para distinguir un dato faltante de una referencia rota.
DQ-017	Negocio	Todo negocio tiene al menos una categoría asignada	Completitud	Alta	98 %	El producto 3 (experiencia por categoría) solo puede analizar negocios categorizados. Se tolera 2 % porque el dataset de Yelp incluye negocios sin categorías: quedan fuera del análisis por categoría, pero sí cuentan en el producto 1. Umbral inicial: confirmarlo con la primera medición.
DQ-018	Negocio-categoría	Cada relación negocio-categoría apunta a un negocio y una categoría existentes	Consistencia	Crítica	100 %	Una relación rota cuenta negocios en categorías inexistentes, o al revés, y altera todos los indicadores del producto 3.
DQ-019	Categoría	Cada categoría aparece una sola vez en el catálogo, sin variantes de mayúsculas o espacios	Unicidad	Alta	100 %	Si una categoría aparece dos veces con distinta escritura, sus negocios se reparten entre ambas y el ranking por categoría sale incorrecto.
DQ-020	Tip	Todo tip tiene un autor y un negocio existentes y una fecha válida	Consistencia	Alta	100 %	Los tips no cuentan para Usuario activo (que exige una reseña válida), pero sí para Usuario contribuidor (is_contributor), tip_count e interaction_count del producto 2. Un tip sin autor,

ID	Entidad	Regla en lenguaje de negocio	Dimensión	Criticidad	Umbral	Por qué ese umbral
						negocio o fecha válidos altera esas métricas.

6.3 Criticidad y tratamiento de fallas

Criticidad	Qué pasa si la regla falla	Quién decide
Crítica	El Quality Gate de `02_silver_limpieza` detiene el job antes de publicar Gold y se envía el correo de falla.	El Data Steward corrige o escala al Data Owner.
Alta	Gold se publica; los registros afectados se marcan o se excluyen de las métricas oficiales (por ejemplo, `is_valid = false`).	El Data Steward revisa en la siguiente ejecución.
Media	Gold se publica; el resultado aparece en la página de la CDO como advertencia.	El Data Owner decide si corrige o acepta el riesgo.

Ninguna falla queda en silencio: si un dato no se puede corregir, el Data Owner firma la aceptación del riesgo y queda en la sección 9.2.

6.4 Resultado de la última corrida

Corrida del 08/11/2026: 18 de 20 reglas cumplen su umbral, ninguna crítica falla y el cumplimiento promedio es 99,53 %. DQ-008 y DQ-011 quedan bajo su umbral; su acción acordada es aceptar el riesgo, lo que requiere la firma del Data Owner (D-10).

ID	Tabla evaluada	Criticidad	Umbral	Resultado	Estado	Acción si falla	Responsable
DQ-001	`yelp_silver.slv_review`	Crítica	100 %	100.0 %	Cumple	Bloquear la publicación en Gold y corregir la deduplicación en 02_silver_limpieza.	Andrew Collins – Producto
DQ-002	`yelp_silver.slv_review`	Alta	99.5 %	99.86 %	Cumple	Marcar is_valid = false en Gold para que no cuenten en el rating. Si supera el umbral, alertar a Trust & Safety para investigación antifraude.	Andrew Collins – Producto; informa a Rafael Nakamura – Trust & Safety
DQ-003	`yelp_silver.slv_review`	Crítica	100 %	100.0 %	Cumple	Enviar a slv_review_quarantine con motivo DQ-003.	Andrew Collins – Producto
DQ-004	`yelp_silver.slv_review`	Crítica	100 %	100.0 %	Cumple	Enviar a slv_review_quarantine con motivo DQ-004.	Andrew Collins – Producto
DQ-005	`yelp_silver.slv_review`	Alta	100 %	100.0 %	Cumple	Enviar a slv_review_quarantine con motivo DQ-005.	Andrew Collins – Producto
DQ-006	`yelp_silver.slv_review`	Crítica	100 %	100.0 %	Cumple	Enviar a slv_review_quarantine y revisar el script de muestreo.	Andrew Collins – Producto

ID	Tabla evaluada	Criticidad	Umbral	Resultado	Estado	Acción si falla	Responsable
DQ-007	`yelp_silver.slv_business`	Media	90 %	99.47 %	Cumple	Aceptar el riesgo documentado: el rating oficial de Producto es el bayesiano, no el declarado. Si baja de 90 %, revisar si la muestra quedó incompleta.	Andrew Collins – Producto
DQ-008	`yelp_silver.slv_business`	Media	98 %	95.04 %	**No cumple**	Aceptar el riesgo hasta el umbral. Si se supera, revisar DQ-002 y DQ-006.	Andrew Collins – Producto
DQ-009	`yelp_silver.slv_checkin`	Alta	100 %	100.0 %	Cumple	Excluir del conteo de visitas y revisar la conversión en 02_silver_limpieza.	Carla Romero – Operaciones Comerciales (Ads)
DQ-010	`yelp_silver.slv_checkin`	Alta	99 %	99.97 %	Cumple	Excluir del conteo oficial de visitas (is_duplicate = true). Si supera el umbral, revisar la fuente con el Ingeniero de datos.	Carla Romero – Operaciones Comerciales (Ads); consulta a Andrew Collins – Producto
DQ-011	`yelp_silver.slv_business`	Alta	98 %	96.39 %	**No cumple**	Aceptar el riesgo hasta el umbral y excluir esos negocios de los mapas.	Andrew Collins – Producto
DQ-012	`yelp_silver.slv_business`	Alta	99 %	100.0 %	Cumple	Revisión manual del Steward: consolidar el registro o documentar la excepción.	Andrew Collins – Producto
DQ-013	`yelp_silver.slv_business`	Media	99 %	99.97 %	Cumple	Excluir de los visuales geográficos y reportar a Producto.	Andrew Collins – Producto
DQ-014	`yelp_silver.slv_user`	Media	99 %	100.0 %	Cumple	Aceptar el riesgo hasta el umbral. Si se supera, usar la fecha de la primera reseña como fecha de alta para la cohorte.	Rafael Nakamura – Trust & Safety; informa a Andrew Collins – Producto
DQ-015	`yelp_silver.slv_review`	Alta	100 %	100.0 %	Cumple	Volver a ejecutar el job. Si persiste, alertar al Ingeniero de datos.	Laura Hernández – CDO (Data Platform)

ID	Tabla evaluada	Criticidad	Umbral	Resultado	Estado	Acción si falla	Responsable
DQ-016	`yelp_silver.slv_review`	Crítica	100 %	100.0 %	Cumple	Enviar a slv_review_quarantine con motivo DQ-016.	Andrew Collins – Producto
DQ-017	`yelp_silver.slv_business`	Alta	98 %	99.94 %	Cumple	Aceptar el riesgo hasta el umbral y excluir esos negocios del análisis por categoría.	Andrew Collins – Producto
DQ-018	`yelp_silver.slv_business_category`	Crítica	100 %	100.0 %	Cumple	Bloquear la actualización de gld_agg_category_month y corregir el pipeline de silver.	Andrew Collins – Producto
DQ-019	`yelp_silver.slv_category`	Alta	100 %	100.0 %	Cumple	Consolidar las variantes en el catálogo de categorías antes de publicar Gold.	Andrew Collins – Producto
DQ-020	`yelp_silver.slv_tip`	Alta	100 %	100.0 %	Cumple	Excluir del conteo de actividad y revisar 02_silver_limpieza.	Andrew Collins – Producto

7 · REQUERIMIENTOS DE INFORMACIÓN Y KPIS (E8)

Cada visual del dashboard responde a una de estas preguntas; un indicador que ningún stakeholder pidió no entra. Los requerimientos de Producto (REQ-P) se agrupan en los tres productos de datos acordados con Andrew Collins: (1) calificación confiable, REQ-P1 a REQ-P3; (2) engagement y retención, REQ-P4 y REQ-P5; (3) experiencia por categoría, REQ-P6 y REQ-P7. REQ-P0 resume los tres en una sola mirada. Los requerimientos de gobierno (REQ-G) responden a la CDO.

7.1 Preguntas de negocio por stakeholder

ID	Pregunta de negocio	Stakeholder	Decisión que habilita	Frecuencia
REQ-P0	¿Cómo está la experiencia hoy, en una sola mirada? Rating válido de 12 meses, usuarios activos, retención a 3 meses y categorías evaluadas, en el último mes completo.	Andrew Collins	Abrir la revisión de Producto con una sola cifra por métrica.	Mensual
REQ-P1	Producto 1 · ¿La experiencia mejora o empeora mes a mes? Rating válido mensual y promedio móvil de 3 meses.	Andrew Collins	Detectar a tiempo una caída de satisfacción y priorizar su causa.	Mensual
REQ-P2	Producto 1 · ¿Qué negocios lideran la experiencia y cuáles empeoraron en los últimos 6 meses? Rating bayesiano de 12 meses, mínimo 20 reseñas válidas.	Andrew Collins, Mei Lin	Alimentar recomendaciones e insignias con un rating que no premie negocios con pocas reseñas extremas.	Mensual
REQ-P3	Producto 1 · ¿Dónde se pierde la confianza en el contenido? Reseñas negativas, reseñas no válidas y brecha con el rating declarado.	Andrew Collins, Rafael Nakamura	Ajustar la moderación y explicar a los comercios la diferencia entre rating declarado y válido.	Mensual
REQ-P4	Producto 2 · ¿Cuántos usuarios activos y contribuidores tenemos cada mes?	Andrew Collins, Jessica Martínez	Medir el engagement con usuarios únicos y no con volumen inflado.	Mensual
REQ-P5	Producto 2 · ¿Los usuarios nuevos se quedan? Porcentaje de cada cohorte anual activo entre los meses 1 y 12 después del alta.	Andrew Collins	Evaluar la salud de la comunidad y el efecto de las insignias de fidelidad.	Trimestral
REQ-P6	Producto 3 · ¿Qué tipo de negocio da mejor y peor experiencia? Rating válido por categoría, 12 meses, mínimo 100 reseñas.	Andrew Collins	Priorizar mejoras y filtros de búsqueda por categoría.	Mensual
REQ-P7	Producto 3 · ¿En qué categorías se concentra la insatisfacción? Porcentaje de reseñas negativas por categoría.	Andrew Collins	Diseñar herramientas de asistencia para las categorías críticas.	Mensual
REQ-G1	¿La calidad de los datos mejora entre corridas?	Laura Hernández	Priorizar el programa de calidad.	Por ejecución
REQ-G2	¿En qué dimensión de calidad fallamos?	Laura Hernández	Asignar esfuerzo de corrección por dimensión.	Por ejecución
REQ-G3	¿Qué reglas fallan hoy, qué se hace y quién responde?	Laura Hernández	Exigir corrección o firma de aceptación de riesgo.	Por ejecución
REQ-G4	¿Está documentado todo lo que publicamos?	Laura Hernández	Cerrar brechas de metadata por capa.	Por ejecución
REQ-G5	¿Cada término y cada entidad tiene dueño?	Laura Hernández	Completar el ownership formal (RACI).	Mensual

ID	Pregunta de negocio	Stakeholder	Decisión que habilita	Frecuencia
REQ-G6	¿El pipeline es estable y cuánto tiempo de cómputo consume?	Laura Hernández	Controlar la cuota (FinOps) y la estabilidad del job.	Diaria

Mes de referencia: el dataset termina a mediados de enero de 2022, así que el dashboard usa el último mes completo (diciembre de 2021). Regla: si el último mes tiene menos del 60 % de las reseñas promedio de los tres meses anteriores, se toma el mes previo. Todas las ventanas de 3, 6 y 12 meses terminan en ese mes.

Fuera del dashboard actual (D-11): check-ins oficiales frente a marcas crudas (Carla Romero), salud de reseñas con cuarentena (Rafael Nakamura) y temas de las reseñas negativas con IA. Los datos ya existen en Gold (gld_agg_business_checkin_day, gld_agg_review_health_month y gld_review_ai_enriched); sus visuales quedan como trabajo futuro.

7.2 Catálogo de KPIs

KPI	Fórmula en lenguaje de negocio	Columna en Gold	Requerimiento	Owner
Calificación válida	Promedio de estrellas de las reseñas válidas del negocio o categoría en el mes.	`gld_agg_business_month.valid_rating`; `gld_agg_category_month.valid_rating`	REQ-P1, REQ-P6	Producto
Rating ponderado bayesiano (BWR)	BWR = (v · R + m · C) / (v + m), con v = reseñas válidas del negocio, R = su promedio, m = 25 y C = promedio de la ciudad.	`gld_agg_business_bayesian_month.bayesian_rating`	REQ-P0, REQ-P2	Producto
Volumen de reseñas válidas	Reseñas válidas recibidas en el periodo.	`gld_agg_business_month.valid_review_count`	REQ-P1, REQ-P6	Producto
Crecimiento neto de reseñas (NRG)	(Válidas del mes − válidas del mes anterior) / válidas del mes anterior × 100.	Calculado con LAG sobre `valid_review_count` en E8	Disponible; sin visual (D-11)	Producto
Tasa de reseñas útiles	Reseñas válidas con al menos un voto útil / reseñas válidas.	`gld_agg_business_month.useful_review_rate`	Disponible; sin visual (D-11)	Producto
Tasa de reseñas negativas	Reseñas válidas de 1 o 2 estrellas / reseñas válidas.	`gld_agg_business_month.negative_review_rate`	REQ-P3, REQ-P7	Producto
Frescura	Días desde la última reseña	`gld_agg_business_month.days_since_last_review`	Disponible; sin visual (D-11)	Producto

KPI	Fórmula en lenguaje de negocio	Columna en Gold	Requerimiento	Owner
	válida del negocio.			
Brecha de calificación	Calificación declarada por Yelp − calificación válida.	`gld_agg_business_month.rating_gap`	REQ-P3	Producto
Check-ins oficiales (HAI)	Check-ins del día sin duplicados exactos; horas distintas con actividad como complemento.	`gld_agg_business_checkin_day.checkin_count`, `active_hour_count`	Disponible; sin visual (D-11)	Op. Comerciales
Salud de reseñas (RHR)	Válidas / (válidas + duplicadas + en cuarentena) × 100.	`gld_agg_review_health_month`	Disponible; sin visual (D-11)	Trust & Safety
Tasa de contenido no válido	Reseñas duplicadas / reseñas del negocio en el mes.	`gld_agg_business_month.invalid_content_rate`	REQ-P3	Trust & Safety
Retención de cohortes (CRR)	Usuarios de la cohorte con al menos una reseña válida en el mes / tamaño de la cohorte.	`gld_agg_user_cohort_month.retention_rate`	REQ-P0, REQ-P5	Producto
Contribuciones por usuario	Reseñas + tips del usuario en el mes.	`gld_agg_user_month.contribution_count`	REQ-P4	Producto
Usuarios activos	Usuarios con al menos una reseña válida en el mes (los tips no cuentan). Los contribuidores (is_contributor) suman reseñas o tips.	`gld_agg_user_cohort_month.active_user_count`; `gld_agg_user_month.is_contributor`	REQ-P0, REQ-P4	Producto
Utilidad comunitaria (CUR)	(useful + funny + cool) / reseñas publicadas.	Consulta sobre `gld_fact_review`	Disponible; sin visual (D-11)	Producto

KPI	Fórmula en lenguaje de negocio	Columna en Gold	Requerimiento	Owner
Salud de calidad	Reglas que cumplen su umbral / total, en la última corrida.	`yelp_gov.dq_results`	REQ-G1, REQ-G2, REQ-G3	CDO
Cobertura de documentación	Columnas de Silver y Gold con descripción en el diccionario / total.	`yelp_gov.data_dictionary`	REQ-G4	CDO
Ownership	Entidades y términos con owner / total.	`yelp_gov.raci_matrix`, `business_glossary`	REQ-G5	CDO

Stickiness (DAU/MAU) queda fuera del alcance: requiere eventos de uso diario que el dataset no contiene (ADR-12).

7.3 Consultas del dashboard (E8)

ID	Consulta	Tablas	Requerimiento
P0	Indicadores del último mes completo	`gld_agg_business_bayesian_month`, `gld_agg_user_cohort_month`, `gld_agg_category_month`	REQ-P0
P1	Rating válido mensual y promedio móvil de 3 meses	`gld_agg_business_bayesian_month`	REQ-P1
P2	Negocios: rating bayesiano de 12 meses y variación de los últimos 6	`gld_agg_business_bayesian_month`, `gld_dim_business`	REQ-P2
P3	Señales de pérdida de confianza en el contenido	`gld_agg_business_month`	REQ-P3
P4	Usuarios activos y contribuidores por mes	`gld_agg_user_cohort_month`, `gld_agg_user_month`	REQ-P4
P5	Retención por año de alta, meses 1 a 12	`gld_agg_user_cohort_month`	REQ-P5
P6	Rating válido por categoría (12 meses, mínimo 100 reseñas)	`gld_agg_category_month`, `gld_dim_category`	REQ-P6
P7	Reseñas negativas por categoría (12 meses, mínimo 100 reseñas)	`gld_agg_category_month`, `gld_dim_category`	REQ-P7
G1	Evolución de la calidad por corrida	`yelp_gov.dq_results`	REQ-G1
G2	Cumplimiento por dimensión (última corrida)	`yelp_gov.dq_results`, `yelp_gov.dq_rules`	REQ-G2
G3	Reglas que no cumplen hoy, con acción y responsable	`yelp_gov.dq_results`, `yelp_gov.dq_rules`	REQ-G3
G4	Cobertura de documentación por capa	`information_schema.columns`, `yelp_gov.data_dictionary`	REQ-G4
G5	Ownership: términos y entidades con dueño	`yelp_gov.business_glossary`, `yelp_gov.raci_matrix`	REQ-G5
G6	Duración del pipeline por día y capa (últimos 14 días)	`yelp_gov.pipeline_run_log`	REQ-G6

Fuente única: E8_dashboard_bi/01_consultas_base_dashboard contiene las 14 consultas, las mismas que usa el archivo YelpConnect_Producto_y_Gobierno.lvdash.json. Todas las consultas P calculan el mes de referencia sobre gld_agg_business_bayesian_month.

7.4 Diseño del dashboard y preguntas para Genie

Página	Audiencia	Visuales	Consultas
Producto	Andrew Collins y equipo de Producto	Indicadores del último mes completo; rating mensual con promedio móvil; ranking de negocios y mayores caídas; señales de pérdida de confianza; usuarios activos y contribuidores; retención por cohorte (mapa de calor); rating y reseñas negativas por categoría.	P0 a P7
Gobierno (CDO)	Laura Hernández, CDO	Calidad por corrida; cumplimiento por dimensión; reglas que fallan con acción y responsable; cobertura de documentación por capa; ownership; duración del pipeline por capa.	G1 a G6

El Genie Space usa las tablas Gold y los sinónimos del glosario (por ejemplo, rating promedio y promedio de estrellas para Calificación Promedio, o calificación bayesiana para el BWR). Cada pregunta de validación tiene una consulta SQL de referencia en el notebook E8, para comprobar que Genie responde lo mismo que el dashboard:

1. ¿Cuántos usuarios activos hubo en el último mes completo de la muestra?
2. ¿Qué 5 categorías tuvieron la peor calificación confiable en el último año?
3. ¿Qué negocios empeoraron más su rating bayesiano en los últimos 6 meses?
4. ¿Qué porcentaje de los usuarios que se unieron en 2018 seguía activo 6 meses después?
5. ¿Cómo evolucionó la calificación confiable de la ciudad mes a mes en el último año?

8 · MODELO OPERATIVO Y CONSIDERACIONES FINOPS

La plataforma opera dentro de la cuota diaria de Databricks Free Edition. Si se agota, el cómputo se apaga hasta el día siguiente, así que cada decisión operativa busca ejecutar menos y mejor.

8.1 Cadencia de ejecución

Proceso	Cadencia	Responsable	Qué hacer si falla
Job `Pipeline_Medallon_YelpConnect_Grupo03`: `01_bronze_ingesta` → `02_silver_limpieza` (incluye E3 y el Quality Gate E5) → `03_gold_productos_datos` → `04_controles_gobierno` (E6)	Diario, 01:00 UTC; cada tarea empieza solo si la anterior terminó bien	Ingeniero de datos de Data Platform	El job envía un correo a `grupo3arqdatos@proton.me`. Se revisa la tarea fallida y se repara el run desde ese punto. Si falló el Quality Gate, decide el Data Steward (sección 6.3).
Glosario y diccionario (E4)	A demanda, cuando cambian las plantillas Excel o el modelo	Steward de gobierno	Los validadores de E4 indican la columna sin documentar o la regla DQ inexistente.
Consultas del dashboard (E8)	Después del job	Analista de BI y Valor	Verificar que los visuales se refresquen.
Bonus de IA (EX)	A demanda; consume cuota de IA	Analista de BI y Valor	Volver a ejecutar sobre la misma muestra de 500 reseñas.

8.2 Configuración del job

Elemento	Configuración real
Dependencias	Cadena de cuatro tareas con `ALL_SUCCESS`.
Timeout	1.200 segundos (20 minutos) por tarea y 3.600 segundos por job.
Notificaciones	Correo ante cualquier falla (`on_failure`).
Corte por calidad	Una regla crítica fallida detiene `02_silver_limpieza` y las tareas siguientes no corren.
Reintentos	No configurados en el job desplegado. El notebook `04_job_orquestacion` los declara; queda pendiente aplicarlos (D-08).
Duración	Entre 8 min 30 s y 8 min 46 s por corrida completa (corridas del 08/11 y 09/11/2026).

8.3 Volumetría y tiempos de la última corrida

Fuente: `yelp_gov.pipeline_run_log`, corrida del 08/11/2026. El tiempo es el de escritura de las tablas; el resto de la corrida corresponde a arranque de cómputo, reglas DQ y controles de gobierno. Silver escribe 9 tablas porque slv_photo existe pero está vacía (D-06).

Capa	Tablas cargadas	Filas escritas	Tiempo de escritura
bronze	5	696.049	29,6 s
silver	9	2.959.358	39,4 s
gold	16	5.643.530	58,6 s

8.4 Supuestos de consumo

1. La muestra de Philadelphia pesa menos de 300 MB en crudo, así que una corrida completa cabe en la cuota de un día.
2. Las tablas Gold quedan materializadas: el dashboard y Genie consultan resultados ya calculados.
3. Los visuales agregan antes de mostrar; nunca se despliegan millones de filas.
4. Auto Loader procesa solo los archivos de reseñas nuevos.
5. El consumo real se mide en la bitácora y estos supuestos se corrigen con lo observado.

8.5 Bitácora de consumo

Fecha	Actividad	Consumo observado	Decisión de ahorro
14/09/2026	Primera corrida sobre el dataset completo (10 GB).	Crítico: 90 % de la cuota diaria en una sola ejecución.	Muestra de una sola ciudad con `preparar_muestra_yelp.py` (ADR-10).
21/09/2026	Notebooks con `display()` y `count()` repetidos en Silver.	Elevado: esperas largas y alto consumo.	Se quitaron los `display()` exploratorios y los conteos se registran una vez por tabla en `pipeline_run_log`.
28/09/2026	Consultas a Gold con escaneos completos.	Moderado: lecturas redundantes.	Se probó `OPTIMIZE ... ZORDER BY (business_id, date)`; no quedó automatizado en el pipeline (D-09).
04/10/2026	Pipeline multitarea completo en Workflows.	Óptimo: unos 6,4 minutos por corrida.	Cómputo serverless bajo demanda.
31/10–07/11/2026	Migración a nombres en inglés y catálogo de 20 reglas.	Nueve corridas fallidas en 02_silver_limpieza; Gold y gobierno no se publicaron.	Se corrigió 02_silver_limpieza; desde entonces todas las corridas del job terminan bien.
08–09/11/2026	Corridas del modelo v1.3 (nombres en inglés, 20 reglas) y verificación del Quality Gate.	Entre 8 min 30 s y 8 min 46 s; 30 tablas escritas en 128 segundos.	Umbral de CE-05 ajustado a 10 minutos (D-12).

9 · TRAZABILIDAD DOCUMENTO ↔ PLATAFORMA

Esta matriz vincula cada sección con el notebook y los objetos que la implementan. Es la que demuestra que lo documentado es lo construido.

9.1 Matriz de trazabilidad

Sección	Notebook del repositorio	Objetos en Databricks	Estado
2.4 Alcance (una ciudad)	`datos/preparar_muestra_yelp.py`, `00_setup/01_verificar_datos_raw`	`/Volumes/workspace/yelp_bronze/raw/`	Implementado
3.3 ABB → SBB	`00_setup/00_configurar_lakehouse`	Esquemas `yelp_bronze`, `yelp_silver`, `yelp_gold`, `yelp_gov`	Implementado
3.2 Ingesta y Bronze	`E7_pipeline_lakehouse/01_bronze_ingesta`	5 tablas `brz_*` y checkpoint de Auto Loader	Ejecutado
4.2-4.3 Modelo físico	`E3_modelo_fisico/01_modelo_fisico_ddl`	10 tablas Silver y 16 Gold con COMMENT, PK/FK, CHECK y Change Data Feed	Ejecutado
4.2 Silver y golden record	`E7_pipeline_lakehouse/02_silver_limpieza`	`slv_*`, incluida `slv_review_quarantine`	Ejecutado
4.3 Gold	`E7_pipeline_lakehouse/03_gold_productos_datos`	`gld_dim_*`, `gld_bridge_*`, `gld_fact_*`, `gld_agg_*`	Ejecutado
6 Reglas de calidad	`E5_calidad_datos/01_reglas_calidad`	`yelp_gov.dq_rules` (20 reglas), `yelp_gov.dq_results`	Ejecutado
5 Gobierno y RACI	`E6_controles_gobierno/01_controles_unity_catalog`	`raci_matrix`, tags, GRANT, `mask_name`, `vw_user_secure`	Ejecutado
Anexo A · Glosario	`E4_diccionario_glosario/01_business_glossary`	`yelp_gov.business_glossary` (39 términos)	Ejecutado
Anexo B · Diccionario	`E4_diccionario_glosario/02_data_dictionary`	`yelp_gov.data_dictionary` (198 columnas)	Ejecutado
8 Operación	`E7_pipeline_lakehouse/04_job_orquestacion`	Job `Pipeline_Medallon_YelpConnect_Grupo03`, `pipeline_run_log`	Ejecutado diario
7 KPIs y dashboard	`E8_dashboard_bi/01_consultas_base_dashboard`	14 consultas (REQ-P0 a REQ-P7, REQ-G1 a REQ-G6), AI/BI Dashboard YelpConnect_Producto_y_Gobierno y Genie Space	Ejecutado
2.4 IA (bonus)	`EX_bonus_ia/01_analisis_ia_resenas`	`gld_review_ai_enriched` (500 reseñas)	Ejecutado

9.2 Registro de discrepancias

Cuando la implementación obliga a cambiar el diseño, se actualiza la sección afectada y se deja constancia aquí. Un cambio documentado suma; uno silencioso resta.

ID	Sección	Qué se diseñó	Qué se implementó	Motivo	Aprobó
D-01	4.2, ADR-03	Categorías como ARRAY en Silver (v0.4, Acta 03).	Catálogo y tabla puente en Silver y Gold.	El modelo lógico vigente exige la relación N:M.	Equipo (v1.3)
D-02	4.3, ADR-14	Claves sustitutas y SCD tipo 2 en las dimensiones.	Claves naturales y estado vigente; historial con Change Data Feed.	Así lo define `yelp_gold.txt`.	Equipo (v1.3)
D-03	ADR-01, Acta 01	Check-in válido por ventana de 60 minutos por usuario.	Sin duplicado exacto de negocio y fecha-hora; horas con actividad como complemento.	El check-in no identifica al usuario.	Pendiente: Producto y Ads
D-04	6.2	12 reglas DQ (v1.2) y 15 reglas (v0.2).	20 reglas, con justificación, acción y responsable.	Se sumaron las que cita el diccionario revisado.	Equipo (v1.3)
D-05	2.4, 4.2	Excluir la red de amigos (documento G3).	`slv_friendship` con 403.613 pares.	Integrada en v1.2 para el análisis de engagement.	Equipo (v1.2)
D-06	4.1	Foto con datos de la muestra.	`slv_photo` creada y vacía.	El dataset descargado no trae photo.json.	Equipo
D-07	Todo el documento	Nombres de tablas y columnas en español.	Nombres en inglés en las cuatro capas, incluido `yelp_gov`.	Alinear con el modelo lógico.	Equipo (v1.3)
D-08	8.2	Un reintento automático por tarea.	Job sin reintentos.	El notebook 04 no se volvió a ejecutar tras el cambio.	Pendiente
D-09	8.5	OPTIMIZE con ZORDER en Silver.	No automatizado en el pipeline.	Se probó de forma manual.	Pendiente
D-10	6.4	DQ-008 (98 %) y DQ-011 (98 %) en verde.	95,04 % y 96,39 %.	Datos declarados por Yelp y negocios sin dirección física.	Pendiente: firma de Andrew Collins
D-11	7.1-7.4	Dashboard con check-ins oficiales, salud de reseñas con cuarentena y temas de IA; consultas Q1 a Q8 (v1.3).	Dashboard de Producto (REQ-P0 a REQ-P7, tres productos) y de la CDO (REQ-G1 a REQ-G6). Check-ins, cuarentena e IA están en Gold, sin visual.	Priorizar el caso de uso de Andrew Collins dentro de la cuota de cómputo.	Pendiente: Producto, Ads y Trust & Safety
D-12	2.5, 8.2	CE-05: corrida completa en menos de 8 minutos.	8 min 30 s a 8 min 46 s; umbral ajustado a 10 minutos.	Las 20 reglas DQ y el arranque serverless suman unos 2 minutos; la cuota diaria sigue holgada.	Pendiente: CDO

ANEXOS

Anexo A · Glosario de términos de negocio

Fuente: `E4_diccionario_glosario/plantillas/Glosario_de_terminos_de_negocio_YelpConnect_PLANTILLA.xlsx`, cargado en `workspace.yelp_gov.business_glossary`. 39 términos en 5 dominios; cada uno con definición técnica que apunta a una columna existente del catálogo.

Término	Dominio	Definición de negocio	Sinónimos (Genie)	Propietario
Check-in	Business Engagement (Actividad Comercial)	Marca de fecha y hora registrada en los datos de YelpConnect para un negocio. La fuente disponible no contiene identificador del usuario que realizó el evento; por ello no acredita visitas físicas ni visitantes únicos.	Registro de check-in; Evento de check-in; Check-in event	Data Owner – Commercial Operations / Operaciones Comerciales (Carla Romero)
Check-in Válido	Business Engagement (Actividad Comercial)	Evento de check-in incorporado al conteo tras superar las reglas de transformación y calidad aplicables. La aceptación del registro no demuestra presencia física, autor individual ni eliminación de duplicados entre personas.	Check-in aceptado; Registro conforme; Valid check-in	Data Owner – Commercial Operations / Operaciones Comerciales (Carla Romero)
Conteo Diario de Check-ins	Business Engagement (Actividad Comercial)	Número de eventos de check-in aceptados y asociados a un negocio durante un día calendario definido. La agregación depende de la zona horaria y del criterio de aceptación; no informa cuántas personas diferentes acudieron.	Check-ins por día; Daily check-in count; Conteo diario validado	Data Owner – Commercial Operations / Operaciones Comerciales (Carla Romero)
Volumen de Check-ins Válidos (HAI)	Business Engagement (Actividad Comercial)	Número de eventos de check-in aceptados para un negocio y periodo definidos. Mide registros procesados bajo una regla común; no equivale a afluencia de personas, visitas verificadas ni usuarios distintos.	Total de check-ins aceptados; Volumen de actividad registrada; Valid check-in volume	Data Owner – Commercial Operations / Operaciones Comerciales (Carla Romero)
Brecha de Calificación	Businesses (Negocios)	Diferencia entre la calificación declarada en el registro del negocio y la calificación promedio calculada a partir de las reseñas del conjunto analizado. Permite identificar discrepancias de fuente o cobertura; no demuestra por sí misma un error.	Diferencia de rating; Rating gap; Desviación de calificación	Data Owner – Product / Producto (Andrew Collins)
Calificación Declarada de Negocio	Businesses (Negocios)	Valor de estrellas proporcionado en el registro maestro del establecimiento. Puede estar redondeado o corresponder a una población distinta de reseñas, por lo que no debe asumirse idéntico al promedio calculado desde la muestra.	Rating de origen; Business stars; Calificación informada	Data Owner – Product / Producto (Andrew Collins)
Calificación Promedio	Businesses (Negocios)	Media aritmética de las puntuaciones de las reseñas incluidas para un negocio y periodo de referencia. Su interpretación requiere indicar qué reseñas entran al cálculo y distinguirla de la calificación que informa el registro maestro.	Rating promedio; Average review rating; Promedio de estrellas	Data Owner – Product / Producto (Andrew Collins)
Categoría Comercial	Businesses (Negocios)	Clasificación que describe el tipo de actividad, producto o servicio de un negocio. Un establecimiento puede estar asociado a más de una categoría; su uso permite segmentar y comparar negocios similares.	Categoría de negocio; Rubro; Business category	Data Owner – Product / Producto (Andrew Collins)

Término	Dominio	Definición de negocio	Sinónimos (Genie)	Propietario
Categoría Principal de Negocio	Businesses (Negocios)	Categoría seleccionada como principal para clasificar un establecimiento en los análisis. Si el negocio tiene varias categorías, el criterio para escoger una debe ser explícito y consistente.	Rubro principal; Primary business category; Categoría predominante	Data Owner – Product / Producto (Andrew Collins)
Negocio	Businesses (Negocios)	Establecimiento incluido en el directorio de YelpConnect, identificado de forma única y descrito mediante atributos como nombre, ubicación, categoría y estado. Es la entidad de referencia para asociar reseñas, tips y check-ins.	Establecimiento; Local registrado; Business	Data Owner – Product / Producto (Andrew Collins)
Negocio Activo	Businesses (Negocios)	Negocio cuyo registro de origen indica un estado operativo abierto. Se interpreta según el atributo de estado disponible y no implica que el establecimiento esté atendiendo al público en el momento de la consulta.	Negocio abierto; Open business; Establecimiento habilitado	Data Owner – Product / Producto (Andrew Collins)
Rating Promedio Ponderado Bayesiano (BWR)	Businesses (Negocios)	Indicador de reputación que combina el promedio de calificaciones observadas de un negocio con un promedio de referencia y un peso de estabilización. Reduce la influencia de negocios con muy pocas reseñas frente a los que tienen mayor volumen.	Calificación bayesiana; Bayesian weighted rating; Rating ajustado	Data Owner – Product / Producto (Andrew Collins)
Autores Únicos de Reseñas	Content (Contenido)	Número de cuentas de usuario diferentes que publicaron al menos una reseña incluida en el universo de medición para un negocio y periodo. Una misma cuenta cuenta una sola vez, aunque haya publicado varias reseñas.	Autores distintos; Unique review authors; Cuentas reseñadoras únicas	Data Owner – Product / Producto (Andrew Collins)
Calificación	Content (Contenido)	Puntuación numérica otorgada por un usuario a un negocio en una reseña. Representa la valoración individual del autor y no debe confundirse con el promedio agregado ni con la calificación declarada del negocio.	Estrellas de reseña; Review stars; Puntuación individual	Data Owner – Product / Producto (Andrew Collins)
Cantidad de Reseñas	Content (Contenido)	Número de registros de reseñas que corresponden al negocio, conjunto o periodo definido. Debe informarse si incluye duplicados, registros en cuarentena o solo reseñas aceptadas; por sí solo no representa satisfacción.	Volumen de reseñas; Total de reseñas; Review count	Data Owner – Product / Producto (Andrew Collins)
Cantidad de Tips	Content (Contenido)	Número de tips registrados para un negocio o publicados por una cuenta durante un periodo. El indicador debe declarar la unidad de análisis para evitar mezclar aportes recibidos por negocio con aportes emitidos por usuario.	Volumen de tips; Tip count; Total de consejos	Data Owner – Product / Producto (Andrew Collins)
Frescura de Reseñas	Content (Contenido)	Número de días transcurridos entre la fecha de referencia del análisis y la fecha de la reseña más reciente incluida para un negocio. Un valor mayor indica menor recencia de contenido; no mide automáticamente calidad del establecimiento.	Antigüedad de última reseña; Review recency; Días sin reseñas	Data Owner – Product / Producto (Andrew Collins)

Término	Dominio	Definición de negocio	Sinónimos (Genie)	Propietario
Reseña	Content (Contenido)	Contenido publicado por un usuario acerca de un negocio que incorpora una puntuación en estrellas y puede incluir un comentario textual. Para su medición debe distinguirse la reseña registrada de la reseña aceptada por controles de calidad.	Review; Opinión de usuario; Valoración escrita	Data Owner – Product / Producto (Andrew Collins)
Tasa de Crecimiento Neto de Reseñas (NRG)	Content (Contenido)	Variación porcentual del volumen de reseñas entre dos periodos comparables para un mismo alcance y una misma regla de aceptación. El resultado indica crecimiento o disminución del volumen, no cambios en la satisfacción del usuario.	Crecimiento de reseñas; Variación de reseñas; Net review growth	Data Owner – Product / Producto (Andrew Collins)
Tasa de Reseñas Negativas	Content (Contenido)	Porcentaje de reseñas incluidas en el análisis cuya puntuación se clasifica como negativa según un umbral de estrellas previamente aprobado. El numerador y el denominador deben usar la misma población de reseñas.	Porcentaje de reseñas negativas; Negative review rate; Tasa de valoraciones bajas	Data Owner – Product / Producto (Andrew Collins)
Tasa de Reseñas Útiles	Content (Contenido)	Porcentaje de reseñas de un universo definido que reciben la cantidad mínima de votos útiles establecida en la ficha del indicador. Requiere explicitar el umbral de utilidad y el tratamiento de reseñas sin votos.	Porcentaje de reseñas útiles; Useful review rate; Tasa de utilidad de reseñas	Data Owner – Product / Producto (Andrew Collins)
Tip	Content (Contenido)	Comentario breve que un usuario comparte sobre un negocio. Constituye un tipo de contribución distinto de la reseña y, por definición, no exige una puntuación en estrellas.	Consejo; Recomendación breve; Quick tip	Data Owner – Product / Producto (Andrew Collins)
Voto de Interacción	Content (Contenido)	Reacción registrada por la comunidad sobre una reseña bajo categorías disponibles, como útil, divertida o genial. Es una valoración del contenido recibido, no una nueva reseña ni una calificación del negocio.	Voto de utilidad; Reacción a reseña; Review feedback	Data Owner – Product / Producto (Andrew Collins)
Cantidad de Reseñas Válidas	Trust & Safety (Confianza y Seguridad)	Número de reseñas que cumplen los controles de calidad declarados para un negocio y periodo. Es un subconjunto del total evaluado y no debe presentarse como cantidad de reseñas auténticas o libres de fraude.	Reseñas aceptadas; Valid review count; Total de reseñas conformes	Data Owner – Trust & Safety (Rafael Nakamura)
Motivo de Rechazo	Trust & Safety (Confianza y Seguridad)	Razón registrada que explica por qué una reseña fue apartada del conjunto aceptado, de acuerdo con una regla o decisión de moderación. Su identificación permite auditar y eventualmente corregir la clasificación.	Causa de rechazo; Rejection reason; Motivo de cuarentena	Data Owner – Trust & Safety (Rafael Nakamura)
Ratio de Salud de Calidad de Reseñas (RHR)	Trust & Safety (Confianza y Seguridad)	Porcentaje de reseñas evaluadas que cumplen las reglas de calidad definidas para su uso analítico. Debe calcularse sobre el mismo universo y periodo que el total evaluado, aclarando qué controles se incluyen.	Tasa de reseñas conformes; Review health ratio; Porcentaje de reseñas aceptadas	Data Owner – Trust & Safety (Rafael Nakamura)

Término	Dominio	Definición de negocio	Sinónimos (Genie)	Propietario
Reseña Duplicada	Trust & Safety (Confianza y Seguridad)	Reseña identificada como repetición de otra conforme a una regla de identificación documentada. La duplicidad por identificador no implica, por sí sola, fraude ni permite detectar todas las reseñas falsas.	Reseña repetida; Duplicate review; Registro duplicado	Data Owner – Trust & Safety (Rafael Nakamura)
Reseña Válida	Trust & Safety (Confianza y Seguridad)	Reseña que supera las reglas de calidad definidas para incorporarse a un conjunto analítico específico. Su condición depende de las reglas aplicadas y no certifica la veracidad de la experiencia narrada ni la identidad del autor.	Reseña aceptada; Reseña conforme; Valid review	Data Owner – Trust & Safety (Rafael Nakamura)
Reseña en Cuarentena	Trust & Safety (Confianza y Seguridad)	Reseña separada del flujo analítico principal por incumplir una regla o requerir revisión. Debe conservar el motivo de separación y permitir distinguir entre rechazo definitivo y tratamiento pendiente.	Reseña retenida; Quarantined review; Reseña excluida temporalmente	Data Owner – Trust & Safety (Rafael Nakamura)
Tasa de Contenido No Válido	Trust & Safety (Confianza y Seguridad)	Porcentaje de reseñas evaluadas que no superan los controles de calidad aplicables para su consumo analítico. Debe aclararse si incluye cuarentena y si comparte el mismo universo con la tasa de reseñas conformes.	Porcentaje de reseñas no conformes; Invalid content rate; Tasa de reseñas excluidas	Data Owner – Trust & Safety (Rafael Nakamura)
Tasa de Cuarentena de Reseñas	Trust & Safety (Confianza y Seguridad)	Porcentaje de reseñas evaluadas que se envían a cuarentena durante el periodo analizado. Debe distinguirse de la proporción de reseñas inválidas cuando existen otros destinos o estados de tratamiento.	Porcentaje de reseñas en cuarentena; Quarantine rate; Review quarantine rate	Data Owner – Trust & Safety (Rafael Nakamura)
Amistad (Red Social)	Users (Usuarios)	Vínculo de amistad registrado entre dos cuentas de YelpConnect. Describe una conexión de la red social y no demuestra interacción fuera de la plataforma ni relación comercial entre ambas personas.	Relación de amistad; Conexión entre usuarios; Friendship	Data Owner – Product / Producto (Andrew Collins)
Cohorte de Usuario	Users (Usuarios)	Conjunto de usuarios cuya fecha de incorporación a YelpConnect pertenece al mismo periodo de referencia, por ejemplo, un mes calendario. La cohorte permanece fija para comparar su participación en periodos posteriores.	Cohorte de registro; Registration cohort; Grupo de alta	Data Owner – Product / Producto (Andrew Collins)
Contribuciones de Usuario	Users (Usuarios)	Número de aportes observables realizados por una cuenta en un periodo, considerando las categorías de contenido previamente definidas –por ejemplo, reseñas y tips–. No incluye navegación no registrada ni interacción presencial inferida.	Aportes de usuario; User contributions; Publicaciones de usuario	Data Owner – Product / Producto (Andrew Collins)
Tamaño de Cohorte	Users (Usuarios)	Número de cuentas que pertenecen a la cohorte definida por su periodo de registro. Constituye la población base para calcular indicadores de retención y debe mantenerse estable entre los periodos comparados.	Usuarios base de cohorte; Cohort size; Población inicial de cohorte	Data Owner – Product / Producto (Andrew Collins)

Término	Dominio	Definición de negocio	Sinónimos (Genie)	Propietario
Tasa de Retención de Cohortes (CRR)	Users (Usuarios)	Proporción de integrantes de una cohorte de registro que vuelve a realizar una contribución observable en el periodo de seguimiento. En este caso mide continuidad de publicación de reseñas o tips; no retención de sesiones ni de uso general de la aplicación.	Retención de contribuidores; Cohort contribution retention; Retention rate	Data Owner – Product / Producto (Andrew Collins)
Usuario	Users (Usuarios)	Persona que dispone de un perfil registrado en YelpConnect y puede generar o recibir interacciones en la plataforma. Se identifica por una cuenta única; no debe equipararse con un visitante anónimo ni con un cliente que haya comprado en un negocio.	Cuenta de usuario; Miembro registrado; Yelp user	Data Owner – Product / Producto (Andrew Collins)
Usuario Activo	Users (Usuarios)	Usuario registrado que realizó al menos una contribución observable –reseña o tip– durante el periodo de medición. Es una definición de actividad basada en contenido publicado: no incluye necesariamente a quienes solo consultaron negocios o abrieron la aplicación.	Usuario con actividad; Active contributor; Usuario participante	Data Owner – Product / Producto (Andrew Collins)
Usuario Élite	Users (Usuarios)	Usuario cuyo perfil tiene asignado el reconocimiento Elite conforme a la información disponible de YelpConnect. Es una condición del perfil, no una medida automática de la calidad de sus reseñas ni de su actividad actual.	Miembro Elite; Yelp Elite; Usuario destacado	Data Owner – Product / Producto (Andrew Collins)

Anexo B · Diccionario de datos e inventario de tablas

Fuente: `Diccionario_de_Datos_YelpConnect_PLANTILLA.xlsx`, cargado en `workspace.yelp_gov.data_dictionary`. Documenta las 198 columnas de Silver y Gold, cada una con descripción, tipo, nulidad, clave, regla DQ, Data Owner, retención y sensibilidad. El detalle completo por columna está en el Excel y en la tabla `data_dictionary`.

Bronze · `workspace.yelp_bronze`

Tabla	Columnas	Filas (última corrida)	Descripción en Unity Catalog
`brz_business`	16	14.577	Capa Bronze (fidelidad al origen): catálogo crudo de negocios locales de YelpConnect, incluyendo estructuras anidadas attributes y hours retenidas bajo Schema-on-Read (ADR-07).
`brz_checkin`	4	12.900	Capa Bronze (fidelidad al origen): registros crudos de check-ins por negocio con marcas temporales concatenadas en texto.
`brz_review`	12	400.000	Capa Bronze (ingesta incremental Auto Loader / cloudFiles): flujo transaccional crudo de reseñas y calificaciones emitidas por usuarios.
`brz_tip`	7	118.572	Capa Bronze (fidelidad al origen): recomendaciones breves (tips) crudas emitidas por usuarios sobre establecimientos comerciales.
`brz_user`	24	150.000	Capa Bronze (fidelidad al origen): perfiles crudos de usuarios registrados en YelpConnect, incluyendo lista de amigos concatenada y contadores de cumplidos.

Silver • `workspace.yelp_silver`

Tabla	Columnas	Filas (última corrida)	Descripción en Unity Catalog
`slv_business`	14	14.577	Maestro de negocios de Philadelphia, tomado del Yelp Open Dataset. Una fila por negocio.
`slv_business_category`	4	63.853	Tabla puente que asocia cada negocio con sus categorías. Una fila por par negocio-categoría.
`slv_category`	4	1.027	Catálogo de categorías de negocio de Yelp (por ejemplo, restaurantes o salones de belleza). Una fila por categoría.
`slv_checkin`	6	1.838.696	Eventos de check-in en negocios de Philadelphia. Una fila por cada fecha-hora de la lista original.
`slv_friendship`	4	403.613	Tabla puente que registra las amistades entre usuarios. Una fila por amistad (el par se guarda una sola vez, con user_id_1 < user_id_2).
`slv_photo`	6	—	Fotos que los usuarios subieron a negocios de Yelp. Una fila por foto. Sin datos en la muestra actual, porque el dataset descargado no incluye photo.json.
`slv_review`	11	373.256	Reseñas escritas por usuarios sobre negocios de Philadelphia. Una fila por reseña.
`slv_review_quarantine`	9	26.744	Reseñas de Bronze que no pasan a slv_review por incumplir una regla de calidad. Una fila por reseña rechazada. Las reseñas duplicadas no se rechazan: quedan en slv_review y Gold las marca como no válidas.
`slv_tip`	8	87.592	Tips (sugerencias cortas) que los usuarios escribieron sobre negocios de Philadelphia. Una fila por tip.
`slv_user`	12	150.000	Maestro de usuarios de Yelp que escribieron reseñas o tips en la muestra de Philadelphia. Una fila por usuario.

Gold • `workspace.yelp_gold`

Tabla	Columnas	Filas (última corrida)	Descripción en Unity Catalog
`gld_agg_business_bayesian_month`	6	158.596	Calificación bayesiana mensual por negocio, para el ranking de Producto (Andrew Collins). Una fila por negocio y mes.
`gld_agg_business_checkin_day`	4	1.361.549	Conteo diario oficial de check-ins por negocio, para Operaciones Comerciales (Carla Romero). Una fila por negocio y día con check-ins.
`gld_agg_business_month`	16	450.490	Indicadores mensuales por negocio. Una fila por negocio y mes.
`gld_agg_business_week`	4	804.976	Engagement semanal por negocio. Una fila por negocio y semana.
`gld_agg_category_month`	8	3.564	Indicadores mensuales por categoría principal. Una fila por categoría y mes.
`gld_agg_review_health_month`	5	201	Salud mensual de las reseñas: válidas, duplicadas y rechazadas, para Trust & Safety (Rafael Nakamura). Una fila por mes.

Tabla	Columnas	Filas (última corrida)	Descripción en Unity Catalog
gld_agg_user_cohort_month	6	17.276	Retención mensual de cohortes de usuarios según su mes de alta, para Producto (Andrew Collins). Una fila por cohorte y mes de actividad.
gld_agg_user_month	6	308.095	Actividad mensual por usuario. Una fila por usuario y mes.
gld_bridge_business_category	3	63.792	Puente entre negocios y categorías. Una fila por par negocio-categoría.
gld_dim_business	7	14.558	Dimensión de negocios de Philadelphia, para análisis. Una fila por negocio maestro (golden record).
gld_dim_category	2	1.027	Dimensión de categorías de negocio. Una fila por categoría.
gld_dim_date	8	9.862	Dimensión de calendario. Una fila por día.
gld_dim_user	6	150.000	Dimensión de usuarios de Yelp, para análisis. Una fila por usuario.
gld_fact_checkin	6	1.838.696	Hechos de check-in. Una fila por check-in. No identifica al usuario.
gld_fact_review	11	373.256	Hechos de reseñas. Una fila por reseña publicada.
gld_fact_tip	6	87.592	Hechos de tips. Una fila por tip.
gld_review_ai_enriched	10	–	EX · Muestra gobernada de reseñas enriquecidas con IA (sentimiento, tópico principal y flag de disonancia). Consumidores: Trust & Safety (Rafael Nakamura) y Producto (Andrew Collins; sin visual en el dashboard actual, D-11).
vw_user_secure	6	–	E6 · Vista segura de usuarios con enmascaramiento dinámico de PII para consumo analítico

Gobierno • `workspace.yelp_gov`

Tabla	Columnas	Filas (última corrida)	Descripción en Unity Catalog
business_glossary	12	–	E4 · Glosario de términos de negocio cargado desde la plantilla institucional. Una fila por término.
data_dictionary	25	–	E4 · Diccionario de datos de Silver y Gold (plantilla institucional + catálogo de Unity Catalog). Una fila por columna física.
dq_results	7	–	E5 · Historial de ejecuciones del motor de calidad (insumo de E7 Quality Gate y E8 Dashboard CDO)
dq_rules	11	–	E5 · Catálogo gobernado de reglas de calidad de datos
pipeline_run_log	5	–	Observabilidad del pipeline: volumetría y duración por corrida
raci_matrix	7	–	E6 · Asignación formal de roles y responsabilidades RACI sobre las entidades de YelpConnect

Anexo C · Archivos fuente y diagramas

Archivo	Contenido
02-Modelado/yelp_modelo_conceptual.drawio	Modelo conceptual (figura 4.1).

Archivo	Contenido
`02-Modelado/yelp_modelo_logico.drawio`	Modelo lógico Silver y dimensional Gold (figuras 4.2 y 4.3).
`02-Modelado/yelp_silver.txt`, `yelp_gold.txt`	DDL de referencia que implementa E3.
`E4_diccionario_glosario/plantillas/`	Plantillas institucionales del glosario y del diccionario.

Anexo D · Actas de decisión del equipo

Acta	Disputa	Resolución	Estado en v1.3
Acta 01 19/08/2026	Conteo de check-ins: Ads contaba cada marca; Producto, un check-in por día.	Ventana de 60 minutos por usuario y negocio. Aprobada por Carla Romero y Andrew Collins.	Ajustada en la implementación (ADR-01, D-03).
Acta 02 02/09/2026	Growth quería mantener todas las reseñas; Trust & Safety, borrar las sospechosas.	Las reseñas que fallan reglas se aíslan en cuarentena para auditoría y no cuentan en el rating público.	Vigente: `slv_review_quarantine` e `is_valid`.
Acta 03 16/09/2026	Categorías en tabla puente o como arreglo.	Arreglo `ARRAY<STRING>` (ADR-03 original).	Reemplazada en v1.3 por la tabla puente (D-01).
Acta 04 30/09/2026	Tabla única desnormalizada frente a modelo estrella.	Modelo estrella con agregados de cohortes (ADR-05).	Vigente.

Anexo E · Referencias regulatorias y de uso

- **Términos de uso del Yelp Open Dataset:** uso académico y no comercial de los datos.
- **RGPD (Unión Europea) y CCPA/CPRA (California):** marcos de referencia para tratar nombres e identificadores de usuarios como datos personales; Yelp opera en más de 30 países.
- **Ley N.° 29733, Ley de Protección de Datos Personales (Perú):** referencia local para la clasificación y el enmascaramiento.

El detalle de qué disposición aplica a cada columna está en la columna Fuente normativa del diccionario.

Anexo F · Supuestos y preguntas abiertas

Supuestos

- Los Data Owners de la sección 5 aceptan su rol sobre las entidades asignadas.
- La experiencia de usuario se aproxima con indicadores de contenido y engagement (ADR-12).
- Philadelphia tiene volumen suficiente: 14.558 negocios, 373.256 reseñas, 87.592 tips y 1.838.696 check-ins en la muestra.

Preguntas abiertas

- ¿Producto y Ads aprueban el criterio de check-in válido implementado (D-03)?
- ¿Andrew Collins firma la aceptación de riesgo de DQ-008 y DQ-011 (D-10)?
- ¿Se aplican los reintentos del job y se automatiza la optimización de tablas (D-08, D-09)?
- ¿Qué criterio adicional de reseña sospechosa acepta Trust & Safety, más allá de duplicados y cuarentena? El análisis de consistencia de `gld_review_ai_enriched` es un candidato.

Aprobación

Rol	Nombre	Firma	Fecha
Sponsor ejecutivo	Laura Hernández, CDO		
Sponsor de negocio y Data Owner	Andrew Collins, VP of Product		
Data Owner de datos personales	Rafael Nakamura, Trust & Safety		
Data Owner de check-ins	Carla Romero, Operaciones Comerciales		
Arquitecto de datos	Jamir Huaman, Grupo 03 · Data Evolution		